



Universitat
de les Illes Balears

TRABAJO FIN DE MÁSTER

**DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN
CORTES CEREBRALES**

Alejandro Rodríguez

**Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos**

Centro de Estudios de Posgrado

Curso académico 2025/26

DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN CORTES CEREBRALES

Alejandro Rodríguez

TRABAJO FIN DE MÁSTER

Centro de Estudios de Posgrado

Universitat de les Illes Balears

Curso académico 2025/26

Palabras clave:

Detección de anomalías, resonancia magnética cerebral, autoencoder, aprendizaje no supervisado, imagen médica, BraTS2021

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau.

Esta obra se distribuye bajo una licencia Creative Commons Reconocimiento 4.0.



Detección no supervisada de anomalías en cortes cerebrales

Alejandro Rodríguez

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

Trabajo Fin de Máster del Máster Universitario en Sistemas Inteligentes (MUSI)
Universitat de les Illes Balears, 07122 Palma, Illes Balears, España

Resumen—Este trabajo desarrolla un detector no supervisado de anomalías en cortes cerebrales de resonancia magnética (FLAIR). Los pesos se aprenden exclusivamente a partir de 7.500 imágenes normales de BraTS2021 (el reto internacional de segmentación de tumores cerebrales). La solución es un autoencoder convolucional de 16.281 parámetros que reconstruye cortes de 240×240 . La puntuación combina el error de reconstrucción calibrado con cuatro señales globales de la imagen (kurtosis, región brillante más grande, gradiente medio, entropía), con un peso calibrado en validación. Se aplica data augmentation (flip + rotación) durante el entrenamiento. El sistema final obtiene AUROC 0,9029 y exactitud balanceada 0,8332 sobre test. Se aporta código reproducible y demostraciones visuales; no se propone su uso para diagnóstico clínico.

Palabras clave—detección de anomalías, resonancia magnética cerebral, autoencoder, aprendizaje no supervisado, imagen médica, BraTS2021.

I. CONTEXTUALIZACIÓN Y MOTIVACIÓN

A. Problema

Los sistemas supervisados necesitan ejemplos representativos y correctamente etiquetados de cada categoría. En radiología, producir estas anotaciones exige tiempo experto, existe variabilidad entre observadores y no es viable enumerar todas las posibles alteraciones. La detección de anomalías ofrece una formulación distinta: aprender la apariencia normal y señalar las muestras que se apartan de ella [1, 2].

Sea x una imagen médica y f_θ un modelo cuyos pesos se ajustan únicamente con el conjunto normal $\mathcal{D}_N$. Se busca una puntuación $s(x)$ que ordene las imágenes no normales por encima de las normales,

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N,$$

sin utilizar ejemplos anómalos para optimizar θ . La salida indica incompatibilidad con la normalidad aprendida; no identifica una enfermedad ni sustituye la interpretación de un profesional.

B. Reconstrucción y anomalía

Un autoencoder comprime una imagen y aprende a reconstruirla [3]. La hipótesis habitual es que, si solo observa normalidad, reconstruirá peor una anomalía. Sin embargo, una red con demasiada capacidad puede copiar también entradas anómalas, y el residuo puede reflejar contraste, encuadre o adquisición en lugar de patología [4]. Por ello, una reconstrucción visualmente buena no garantiza una puntuación discriminativa.

C. Pregunta, alcance y aportaciones

La pregunta principal es: *¿puede un autoencoder sencillo, entrenado solo con cortes cerebrales normales, separar de forma útil y reproducible las imágenes normales de las no normales en BraTS2021?*

“Anómala” significa *no normal según la anotación de BMAD*; no equivale a confirmar ninguna patología específica. Las aportaciones son: (i) implementación reproducible

del detector; (ii) un protocolo que separa entrenamiento, calibración y prueba; (iii) un autoencoder convolucional final a 240×240 con data augmentation; (iv) evaluación con campaña final con semilla fija; y (v) código, pesos y demostración reproducibles.

II. OBJETIVOS

A. Objetivo general

Diseñar, implementar y evaluar un sistema no supervisado, sencillo y reproducible para detectar anomalías en cortes cerebrales de resonancia magnética, basado en reconstrucción con autoencoder.

B. Objetivos específicos

1. Revisar la detección de anomalías basada en reconstrucción y justificar sus supuestos y puntuaciones mediante bibliografía.
2. Obtener y auditar BraTS2021, verificando conteos, formato y legibilidad.
3. Implementar un autoencoder convolucional con preprocesado común, data augmentation y puntuación por imagen.
4. Evitar fuga de información: entrenar pesos solo con normales, calibrar en validación y evaluar en test.
5. Alcanzar una separación útil con una solución explicable.
6. Entregar un experimento reproducible con demostraciones visuales, documentando limitaciones y uso no clínico.

III. FUNDAMENTOS Y ESTADO DEL ARTE

El AE minimiza el error de reconstrucción $\mathcal{L}_{AE} = \|x - g_\theta(f_\phi(x))\|_1$. Es la alternativa más directa, pero su cuello de botella no impone una distribución latente y el residuo puede reflejar propiedades de adquisición en lugar de patología. La literatura ha explorado variantes más complejas: el autoencoder variacional regulariza el espacio latente [5], modelos generativos adversariales [6], y variantes para imagen médica [7, 8]. Benchmarks como MVTec AD y BMAD consolidan protocolos comunes [9, 10]. Aquí se busca la mínima solución defendible para la pregunta planteada.

IV. DATOS Y METODOLOGÍA

A. Dataset y preprocesado

BraTS (del inglés *Brain Tumor Segmentation*, “segmentación de tumores cerebrales”) es un reto internacional que publica anualmente resonancias magnéticas (RM) de cerebro anotadas por especialistas para permitir comparar métodos de análisis de imágenes médicas. **BraTS2021** es la edición de 2021 de ese reto, y su conjunto de imágenes es un estándar de facto en el campo.

BraTS2021_slice es la partición de cortes cerebrales FLAIR del benchmark BMAD [10]. La modalidad FLAIR es un tipo de secuencia de RM que realza las lesiones cerebrales; cada “imagen” es un corte (slice) 2D extraído de una volumetría completa. La partición contiene 7.500 imágenes normales para

entrenamiento; 39 normales y 44 anómalas para validación; y 640 normales y 3.075 anómalas para test. Las imágenes son PNG monocromos de 240×240 píxeles (resolución nativa).

Las imágenes se escalan a $[0, 1]$. Durante el entrenamiento se aplica data augmentation automática: flip horizontal (50 %), flip vertical (50 %) y rotación aleatoria de 90/180/270°.

B. Arquitectura final

La solución es un autoencoder convolucional simple. Un codificador de tres etapas convolucionales de paso 2 reduce la imagen de 240×240 a un cuello de botella de 30×30 con 32 canales (1 → 8 → 16 → 32); el decodificador simétrico recupera la resolución original con convoluciones transpuestas (32 → 16 → 8 → 1). Se usa ReLU y una sigmoide de salida. No hay conexiones de salto, atención ni red preentrenada. El modelo suma 16.281 parámetros.




Figura 1: Arquitectura del autoencoder convolucional. El codificador reduce el corte cerebral con tres convoluciones de paso 2 hasta un cuello de botella de 30×30×32; el decodificador recupera la resolución original con convoluciones transpuestas. ReLU tras cada convolución, sigmoide a la salida.

C. Puntuación y calibración

El modo de puntuación híbrido combina señales globales con el error de reconstrucción:

$$s(x) = w \cdot z(\text{global}) + (1 - w) \cdot z(\text{MAE}).$$

Aquí x es un corte cerebral y $s(x)$ es la puntuación final de anomalía: cuanto mayor sea $s(x)$, más anómala se considera la imagen. La fórmula tiene tres elementos:

- **$z(\text{MAE})$** : error de reconstrucción estandarizado. El autoencoder se entrena solo con imágenes normales, por lo que reconstruye bien las normales (MAE bajo) y mal las anómalas (MAE alto). El MAE bruto ($\text{MAE}(x) = \frac{1}{N} \sum_p |x(p) - \hat{x}(p)|$) se estandariza con la media μ y desviación σ del MAE sobre las normales de entrenamiento:

$$z(\text{MAE}) = \frac{\text{MAE}(x) - \mu_{\text{MAE}}}{\sigma_{\text{MAE}}}.$$

Valores positivos indican que la imagen se reconstruye peor de lo típico en normales, señal de anomalía.

- **$z(\text{global})$** : suma de las cuatro señales globales (kurtosis, región brillante más grande, gradiente medio y entropía), cada una estandarizada contra su distribución en las normales de entrenamiento y con el signo fijado según la dirección del AUROC en validación. Así, valores altos acumulan características estadísticas propias de lesiones.
- **w** : peso de mezcla en $[0, 1]$ que equilibra ambas fuentes. Se elige en validación maximizando el AUROC sobre una rejilla de 21 valores y se congela para el test. En la campaña final $w = 0,95$: las señales globales dominan y el MAE actúa como señal complementaria.

Señales globales

Las señales globales (`features.py`) son cuatro estadísticos calculados sobre cada imagen que capturan propiedades de su distribución de intensidades:

- **Kurtosis**: mide la *coludad* de la distribución de intensidades. Valores altos indican colas pesadas o picos pronunciados, típicos de estructuras anómalas con contraste extremo.
- **Región brillante más grande (`cc_largest`)**: tamaño (en píxeles) de la componente conexas más grande por encima de un umbral de intensidad. Captura la presencia de regiones brillantes patológicas como edema o tumores con realce.
- **Grado medio**: media del magnitud del gradiente de la imagen. Refleja la cantidad de bordes y texturas; las anomalías suelen generar patrones de borde adicionales por la presencia de lesiones.
- **Entropía**: mide la incertidumbre o desorden en la distribución de intensidades. Lesiones y estructuras anómalas pueden alterar la entropía global de la imagen.

Métricas de evaluación

- **AUROC** (área bajo la curva ROC; ROC viene del inglés *Receiver Operating Characteristic*): la curva ROC representa, para cada posible umbral, el par (tasa de falsos positivos, tasa de verdaderos positivos) del clasificador. El área bajo esa curva mide, de forma resumida y sin depender de un umbral concreto, la capacidad del sistema para distinguir imágenes anómalas de normales: equivale a la probabilidad de que, ante una imagen anómala y una normal elegidas al azar, el sistema puntúe más alto la anómala. Un valor de 0,5 equivale a adivinar al azar y 1 a discriminación perfecta. Es la métrica principal por ser independiente del umbral elegido.
- **Balanced accuracy**: media de sensitivity y specificity. Evita que la clase mayoritaria (anómalas, 83 % del test) domine la métrica.
- **Sensitivity (recall)**: proporción de anómalas correctamente detectadas. $TP / (TP + FN)$.
- **Specificity**: proporción de normales correctamente identificadas. $TN / (TN + FP)$.
- **Umbral**: puntuación que maximiza la balanced accuracy en validación. Se congela y aplica sin cambios en test.

La exactitud balanceada de validación determina el umbral. Las etiquetas de validación intervienen en esta calibración, pero nunca actualizan pesos; por ello el aprendizaje del modelo es no supervisado y la decisión es calibrada. El test se evalúa después sin cambios.

D. Reproducibilidad

El repositorio fija semillas, guarda configuración, historial, puntuaciones y métricas. La campaña final usa la semilla 42 con 10 épocas y data augmentation. Se entrega el checkpoint del modelo final y una demostración que reproduce exactamente su calibración y umbral.

V. RESULTADOS Y ANÁLISIS

Métrica	Valor	Interpretación
AUROC	0,9029	Probabilidad de puntuar más alto una anómala que una normal
Balanced accuracy	0,8332	Media de sensitivity y specificity
Sensitivity	0,7554	Proporción de anomalías correctamente detectadas
Specificity	0,9109	Proporción de normales correctamente identificadas
Peso híbrido (w)	0,95	95 % señales globales + 5 % MAE
Épocas	10	Convergencia en entrenamiento
Parámetros	16.281	Modelo ligero

El peso híbrido seleccionado en validación es $w = 0,95$: las señales globales dominan la separación y el MAE actúa como señal complementaria. Esto indica que las características estadísticas de la imagen (kurtosis, región brillante, gradiente, entropía) contienen más información discriminativa que el error de reconstrucción del autoencoder. La specificity en test supera el 91 % mientras la sensitivity se mantiene por encima del 75 %.

La tabla de señales globales seleccionadas por el modelo muestra los signos fijados en validación (Tabla 1), que determinan la dirección en la que cada señal contribuye a la detección de anomalías.

Señal global	Signo
Kurtosis	+1 (más kurtosis → más anómalo)
Región brillante más grande	+1 (región más grande → más anómalo)
Grado medio	-1 (menos gradiente → más anómalo)
Entropía	+1 (más entropía → más anómalo)

Cuadro 1: Signos de las señales globales fijados en validación según la dirección del AUROC.




Figura 2: Reconstrucciones del autoencoder sobre imágenes normales de test. Fila superior: originales. Fila inferior: reconstrucciones. El modelo reconstruye fielmente la anatomía normal.

A. Demostración con el modelo congelado

Para ilustrar el entregable se fija el checkpoint del modelo final y se procesan imágenes del conjunto de prueba con exactamente la misma calibración y umbral del experimento.

La reconstrucción del caso normal es fiel y su puntuación queda muy por debajo del umbral. En el caso anómalo la puntuación lo supera claramente. La decisión se presenta como el resultado de la fórmula híbrida calibrada completa. Las figuras advierten expresamente de su uso experimental y no clínico.




Figura 3: Demostración con un corte cerebral normal. Los seis paneles muestran: original, reconstrucción, mapa de error, regiones anómalas detectadas, señales globales y gauge del score frente al umbral. Resultado: NORMAL.




Figura 4: Demostración con un corte cerebral anómalo. Con la misma calibración y umbral, la puntuación supera claramente el umbral y la etiqueta resultante es ANÓMALA.

VI. CONCLUSIONES

Se ha cumplido la propuesta: se obtuvo y auditó BraTS2021, se implementó el autoencoder convolucional con data augmentation, se entrenaron los pesos solo con imágenes normales y se evaluó mediante un protocolo reproducible. El resultado es un sistema explicable: tres etapas de codificación, 16.281 parámetros, 10 épocas, y una fórmula de puntuación híbrida explícita con AUROC 0,9029 y exactitud balanceada 0,8332.

La principal conclusión es que un autoencoder sencillo, combinado con señales globales y calibración adecuada, logra una separación útil en cortes cerebrales. El data augmentation contribuye a la generalización y el score híbrido con $w = 0,95$ demuestra que las señales globales contienen información discriminativa complementaria al error de reconstrucción.

Como trabajo futuro se propone validar en otro centro, explorar el uso de U-Net con conexiones de salto, y analizar por subgrupos qué anomalías se detectan mejor. El software actual debe considerarse experimental y no apto para decisiones asistenciales.

BIBLIOGRAFÍA

- [1] Guansong Pang, Chunhua Shen, Longbing Cao y Anton van den Hengel. «Deep Learning for Anomaly Detection: A Review». En: *ACM Computing Surveys* 54.2 (2021), págs. 1-38. doi: [10.1145/3439950](https://doi.org/10.1145/3439950).
- [2] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich y Klaus-Robert Müller. «A Unifying Review of Deep and Shallow Anomaly

- Detection». En: *Proceedings of the IEEE* 109.5 (2021), págs. 756-795. doi: [10.1109/JPROC.2021.3052449](https://doi.org/10.1109/JPROC.2021.3052449).
- [3] Geoffrey E. Hinton y Ruslan R. Salakhutdinov. «Reducing the Dimensionality of Data with Neural Networks». En: *Science* 313.5786 (2006), págs. 504-507. doi: [10.1126/science.1127647](https://doi.org/10.1126/science.1127647).
 - [4] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni y Nassir Navab. «Autoencoders for Unsupervised Anomaly Segmentation in Brain MR Images: A Comparative Study». En: *Medical Image Analysis* 69 (2021), pág. 101952. doi: [10.1016/j.media.2020.101952](https://doi.org/10.1016/j.media.2020.101952).
 - [5] Diederik P. Kingma y Max Welling. «Auto-Encoding Variational Bayes». En: *International Conference on Learning Representations*. 2014. arXiv: [1312.6114](https://arxiv.org/abs/1312.6114).
 - [6] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville y Yoshua Bengio. «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems*. Vol. 27. 2014, págs. 2672-2680.
 - [7] Haibo Zhang, Wenping Guo, Shiqing Zhang, Hongsheng Lu y Xiaoming Zhao. «Unsupervised Deep Anomaly Detection for Medical Images Using an Improved Adversarial Autoencoder». En: *Journal of Digital Imaging* 35.2 (2022), págs. 153-161. doi: [10.1007/s10278-021-00558-8](https://doi.org/10.1007/s10278-021-00558-8).
 - [8] Mariana-Iuliana Georgescu. «Masked Autoencoders for Unsupervised Anomaly Detection in Medical Images». En: *Procedia Computer Science: KES 2023*. 2023. arXiv: [2307.07534](https://arxiv.org/abs/2307.07534).
 - [9] Paul Bergmann, Michael Fauser, David Sattlegger y Carsten Steger. «MVTec AD: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, págs. 9592-9600. doi: [10.1109/CVPR.2019.00982](https://doi.org/10.1109/CVPR.2019.00982).
 - [10] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang y Xingyu Li. «BMAD: Benchmarks for Medical Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2024, págs. 4042-4053.