



Universitat
de les Illes Balears

TRABAJO FIN DE MÁSTER

**DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN
RADIOGRAFÍAS DE TÓRAX**

Alejandro Rodríguez

**Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos**

Centro de Estudios de Posgrado

Curso académico 2025/26

DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN RADIOGRAFÍAS DE TÓRAX

Alejandro Rodríguez

TRABAJO FIN DE MÁSTER

Centro de Estudios de Posgrado

Universitat de les Illes Balears

Curso académico 2025/26

Palabras clave:

Detección de anomalías, radiografía de tórax, autoencoder, aprendizaje no supervisado, imagen médica

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau.

Esta obra se distribuye bajo una licencia Creative Commons Reconocimiento 4.0.



Detección no supervisada de anomalías en radiografías de tórax

Alejandro Rodríguez

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

Trabajo Fin de Máster del Máster Universitario en Sistemas Inteligentes (MUSI)
Universitat de les Illes Balears, 07122 Palma, Illes Balears, España

Resumen—Este trabajo desarrolla un detector no supervisado de anomalías en radiografías de tórax. Los pesos se aprenden exclusivamente a partir de 8.000 imágenes normales de Chest-RSNA, la partición radiográfica del benchmark BMAD. La solución es un autoencoder de reconstrucción tipo U-Net de 366.433 parámetros a 512×512 con conexiones de salto, que reconstruye con gran nitidez las radiografías normales; su puntuación combina, con pesos fijos e iguales, el error de reconstrucción calibrado y una diferencia centro–borde de intensidad. Las direcciones de las señales y el umbral se fijan exclusivamente con validación; el conjunto de prueba permanece congelado. Con la semilla 42 el sistema obtiene AUROC 0,6574 y exactitud balanceada 0,6224 sobre test, por encima de un control estadístico de gradiente (0,5981). La fidelidad de la reconstrucción es el objetivo del entregable final: se aporta código reproducible y una demostración visual con un único modelo congelado; no se propone su uso para diagnóstico clínico.

Palabras clave—detección de anomalías, radiografía de tórax, autoencoder, aprendizaje no supervisado, imagen médica.

I. CONTEXTUALIZACIÓN Y MOTIVACIÓN

A. Problema

Los sistemas supervisados necesitan ejemplos representativos y correctamente etiquetados de cada categoría. En radiología, producir estas anotaciones exige tiempo experto, existe variabilidad entre observadores y no es viable enumerar todas las posibles alteraciones. La detección de anomalías ofrece una formulación distinta: aprender la apariencia normal y señalar las muestras que se apartan de ella [1, 2].

Sea x una radiografía y f_θ un modelo cuyos pesos se ajustan únicamente con el conjunto normal $\mathcal{D}_N$. Se busca una puntuación $s(x)$ que ordene las imágenes no normales por encima de las normales,

$$s(x_N) < s(x_A), \quad x_N \sim P_N, \quad x_A \not\sim P_N,$$

sin utilizar ejemplos anómalos para optimizar θ . La salida indica incompatibilidad con la normalidad aprendida; no identifica una enfermedad ni sustituye la interpretación de un profesional.

B. Reconstrucción y anomalía

Un autoencoder comprime una imagen y aprende a reconstruirla [3]. La hipótesis habitual es que, si solo observa normalidad, reconstruirá peor una anomalía. Sin embargo, una red con demasiada capacidad puede copiar también entradas anómalas, y el residuo puede reflejar contraste, encuadre o adquisición en lugar de patología [4]. Por ello, una reconstrucción visualmente buena no garantiza una puntuación discriminativa.

El VAE regulariza el espacio latente mediante la divergencia de Kullback–Leibler [5]. Las redes generativas adversariales enfrentan generador y discriminador [6]; AnoGAN y GANomaly adaptan este aprendizaje a detección de anomalías [7, 8]. También se han estudiado autoencoders adversariales, VAE en cascada y modelos enmascarados en imagen médica [9,

10, 11, 12]. Su mayor complejidad, no obstante, no implica automáticamente un mejor resultado.

C. Pregunta, alcance y aportaciones

La pregunta principal es: ¿puede un autoencoder sencillo, entrenado solo con radiografías normales, separar de forma útil y reproducible las imágenes normales de las no normales en Chest-RSNA? La comparativa se limita a un control estadístico no neuronal y a la propia historia del modelo.

“Anómala” significa *no normal según RSNA/BMAD*; no equivale a confirmar neumonía ni abarca cualquier patología torácica. Las aportaciones son: (i) un dataset público auditado; (ii) una implementación reproducible del detector; (iii) un protocolo que separa entrenamiento, calibración y prueba; (iv) un autoencoder U-Net final a 512×512 que reconstruye casi fielmente las radiografías normales; (v) evaluación con controles simples y una semilla fija para el modelo final; y (vi) código, pesos y demostración reproducibles sin redistribuir imágenes médicas.

II. OBJETIVOS

A. Objetivo general

Diseñar, implementar y evaluar un sistema no supervisado, sencillo y reproducible para detectar anomalías en radiografías de tórax, basado en reconstrucción y bajo un protocolo común.

B. Objetivos específicos

1. Revisar la detección de anomalías basada en reconstrucción y justificar sus supuestos, puntuaciones y riesgos mediante bibliografía.
2. Obtener y auditar un conjunto con entrenamiento normal, validación y prueba, verificando conteos, formato y legibilidad de las imágenes.
3. Implementar el autoencoder de reconstrucción con un pre-procesado común y una puntuación por radiografía.
4. Evitar fuga de información: entrenar pesos solo con normales, elegir calibración y umbral en validación y evaluar después en test.
5. Alcanzar una separación útil y una reconstrucción lo bastante nítida para una demostración visual con una solución fácil de explicar.
6. Comparar efectividad y coste mediante AUROC, exactitud balanceada y número de parámetros.
7. Entregar un experimento reproducible y una demostración mínima con un único checkpoint, documentando limitaciones y uso no clínico.

Quedan fuera del alcance la localización de lesiones, el diagnóstico por patología, la validación clínica y una búsqueda exhaustiva de arquitecturas. Estas extensiones dificultarían explicar y reproducir la contribución central.

III. FUNDAMENTOS Y ESTADO DEL ARTE

El AE minimiza el error de reconstrucción $\mathcal{L}_{AE} = \|x - g_{\theta}(f_{\phi}(x))\|_1$. Es la alternativa más directa, pero su cuello de botella no impone una distribución latente y el residuo puede reflejar propiedades de adquisición en lugar de patología. La literatura ha explorado variantes más complejas: el autoencoder variacional regulariza el espacio latente mediante la divergencia de Kullback–Leibler [5], los modelos generativos adversariales enfrentan un generador y un discriminador [6], y AnoGAN y GANomaly adaptan ese aprendizaje a la detección de anomalías [7, 8]. También se han estudiado autoencoders adversariales, VAE en cascada y modelos enmascarados en imagen médica [9, 10, 11, 12]. Su mayor complejidad, no obstante, no implica automáticamente un mejor resultado. Benchmarks como MVTEC AD consolidaron protocolos comunes [13]; BMAD trasladó esta evaluación a varios dominios médicos y quince algoritmos [14]. Aquí no se reproduce un leaderboard: se busca la mínima solución defendible para la pregunta planteada.

IV. DATOS Y METODOLOGÍA

A. Dataset y preprocesado

Chest-RSNA es la reorganización realizada por BMAD del desafío de neumonía de RSNA [14, 15]. Contiene 8.000 imágenes normales para entrenamiento; 70 normales y 1.420 anómalas para validación; y 781 normales y 16.413 anómalas para test. En total se verificaron 26.684 PNG monocromos de 1024×1024. No se incluyen en el repositorio por tamaño y condiciones de uso.

Las imágenes se convierten a un canal, se redimensionan bilinealmente a 512×512 y se escalan a [0, 1]. Esta resolución conserva estructura anatómica suficiente para una reconstrucción visualmente fiel y obliga a entrenar en GPU. La reconstrucción puede perder hallazgos muy pequeños y se declara como limitación; resoluciones inferiores (64×64 y 256×256) se usaron durante el desarrollo pero se descartaron por producir reconstrucciones demasiado gruesas.

B. Arquitectura final

La solución final es un autoencoder tipo U-Net [16]. Un codificador de cuatro etapas convolucionales de paso 2 reduce la imagen de 512×512 a un cuello de botella de 32 × 32 con 128 canales (1 → 16 → 32 → 64 → 128); el decodificador simétrico recupera la resolución original con convoluciones transpuestas y cada etapa concatena, mediante una conexión de salto, la salida de su etapa codificadora homóloga. Se usa ReLU y una sigmoide de salida. No hay atención, red preentrenada, ensemble ni clasificador. El modelo suma 366.433 parámetros y se entrena tres épocas con Adam, tasa 10^{-3} , lotes de 32 y pérdida MAE, con la semilla 42. El MAE medio de reconstrucción en validación desciende a 0,0069, un orden de magnitud por debajo del AE mínimo a 64×64 (0,0208).

C. Puntuación y calibración

El experimento inicial mostró un resultado contraintuitivo: en este dataset las anómalas podían presentar menor MAE que las normales. En lugar de añadir otro modelo, se conserva la dirección más discriminativa seleccionada en validación. También se calcula una única estadística fija y transparente,

$$c(x) = \text{media}(\text{centro}) - \text{media}(\text{borde}),$$

donde el centro es la región central de mitad de lado y el borde la banda exterior restante; recoge cambios globales de encuadre e intensidad observados en el análisis de errores.




Figura 1: Arquitectura del autoencoder final tipo U-Net. El codificador reduce la radiografía con cuatro convoluciones de paso 2 hasta un cuello de botella de 32 × 32 × 128; el decodificador recupera la resolución original con convoluciones transpuestas y concatena mediante conexiones de salto la activación de su etapa codificadora homóloga.

Tras fijar en validación el signo de MAE y de $c(x)$, ambas señales se tipifican respecto a las normales de entrenamiento y se promedian sin pesos ajustables:

$$s(x) = 0,5 z(\text{MAE}(x)) + 0,5 z(c(x)).$$

La exactitud balanceada de validación determina el umbral. Las etiquetas de validación intervienen en esta calibración, pero nunca actualizan pesos; por ello el aprendizaje del modelo es no supervisado y la decisión es calibrada, no completamente libre de etiquetas. El test se evalúa después sin cambios. La métrica principal es AUROC. La exactitud balanceada evalúa la decisión en el umbral seleccionado sin permitir que la clase mayoritaria domine el resultado.

D. Reproducibilidad y controles

El repositorio fija semillas, guarda configuración, historial, puntuaciones y métricas. Una ejecución solo se incorpora a la tabla científica si usa las 26.684 imágenes, la semilla 42 y el presupuesto completo. Se entrega el checkpoint U-Net de la semilla 42 y una demostración que reproduce exactamente su calibración y umbral.

Como control no neuronal se evaluaron nueve estadísticas predefinidas de intensidad y textura. Cada señal se seleccionó y umbralizó exclusivamente en validación. Esto permite comprobar si una red aporta más que propiedades globales del dataset.

V. RESULTADOS Y ANÁLISIS

Método	Parámetros	AUROC	Bal. acc.
Control de gradiente	0	0,5981	0,5894
AE mínimo 64×64	16.281	0,7608	0,6790
U-Net final 512×512	366.433	0,6574	0,6224

El U-Net final alcanza AUROC 0,6574 y exactitud balanceada 0,6224 con la semilla 42, por encima del control de gradiente (0,5981). El AE mínimo a 64×64 obtuvo el mayor AUROC (0,7608): su cuello de botella muy estrecho favorece la separación, pero su reconstrucción a 64×64 es demasiado gruesa para resultar presentable. El U-Net a 512×512 invierte parte de esa separación en fidelidad: reduce el MAE de reconstrucción en un orden de magnitud y reproduce casi perfectamente la anatomía normal, que es lo que se muestra en la

demostración. El control de gradiente llega a 0,5981: confirma que el dataset contiene una señal global sencilla que el U-Net calibrado complementa.

AUROC y exactitud balanceada resumen respectivamente la capacidad de ordenar las imágenes y el comportamiento de la decisión final. No se reporta accuracy convencional porque el 95,46 % del test es anómalo y esa métrica resultaría engañosa. Tampoco debe interpretarse el resultado como evidencia clínica. La diferencia centro–borde puede reflejar protocolo, contraste, edad o encuadre, y no necesariamente una lesión. El sistema es un detector del benchmark, no un diagnóstico.

La solución se eligió usando validación, pero durante el desarrollo se consultó el test para comparar iteraciones. Aunque la campaña final congela el método y la semilla, una estimación completamente independiente requiere otro centro o dataset externo. Esta limitación se explicita para evitar una afirmación de generalización que los datos actuales no permiten.

A. Demostración con el modelo congelado

Para ilustrar el entregable se fija el checkpoint U-Net de la semilla 42 y se procesan dos radiografías del conjunto de prueba con exactamente la misma calibración y umbral del experimento.




Figura 2: Demostración con una radiografía normal. Cada panel muestra la imagen original preprocesada, su reconstrucción con el U-Net congelado, el error absoluto por píxel y la puntuación calibrada frente al umbral; la etiqueta resultante es NORMAL.

La reconstrucción del caso normal es prácticamente indistinguible de la original y su puntuación queda muy por debajo del umbral (-2,1857). En el caso anómalo la puntuación alcanza 1,3652 y la imagen se clasifica como anómala. En este dataset el error de reconstrucción no crece siempre ante una anomalía; para estas imágenes es la señal centro–borde la que sostiene la separación, y por eso la decisión se presenta siempre como el resultado de la fórmula calibrada completa y no como un umbral sobre el residuo. Las figuras advierten expresamente de su uso experimental y no clínico.

VI. CONCLUSIONES

Se ha cumplido la propuesta: se obtuvo y auditó ChestRSNA, se implementó el autoencoder de reconstrucción, se entrenaron los pesos solo con imágenes normales y se evaluó mediante un protocolo reproducible. Las primeras arquitecturas no ofrecieron una separación útil y la solución final




Figura 3: Demostración con una radiografía anómala. Con la misma calibración y umbral, la puntuación supera el umbral y la etiqueta resultante es ANOMALA.

combina la reconstrucción con una señal fija. El resultado es un autoencoder U-Net a 512×512 que reconstruye casi fielmente las radiografías normales y cuya puntuación calibrada separa normalidad y anomalía con AUROC 0,6574 y exactitud balanceada 0,6224.

La principal conclusión es metodológica. El error de reconstrucción no siempre crece ante una anomalía y su dirección debe verificarse, no asumirse. Una señal fija centro–borde, combinada a partes iguales con MAE, sostiene la separación cuando el modelo reconstruye bien ambas clases. Fidelidad de reconstrucción y separación estadística compiten: exigir la primera, necesaria para una demostración presentable, reduce la segunda. El resultado es un sistema explicable: cuatro etapas de codificación con salto, tres épocas, un único checkpoint y una fórmula de puntuación explícita.

Como trabajo futuro se propone validar sin reajuste en otro centro, estudiar resoluciones intermedias y analizar por subgrupos qué anomalías se detectan. Solo después de esa validación tendría sentido explorar modelos más complejos. El software actual debe considerarse experimental y no apto para decisiones asistenciales.

BIBLIOGRAFÍA

- [1] Guansong Pang, Chunhua Shen, Longbing Cao y Anton van den Hengel. «Deep Learning for Anomaly Detection: A Review». En: *ACM Computing Surveys* 54.2 (2021), págs. 1-38. DOI: [10.1145/3439950](https://doi.org/10.1145/3439950).
- [2] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich y Klaus-Robert Müller. «A Unifying Review of Deep and Shallow Anomaly Detection». En: *Proceedings of the IEEE* 109.5 (2021), págs. 756-795. DOI: [10.1109/JPROC.2021.3052449](https://doi.org/10.1109/JPROC.2021.3052449).
- [3] Geoffrey E. Hinton y Ruslan R. Salakhutdinov. «Reducing the Dimensionality of Data with Neural Networks». En: *Science* 313.5786 (2006), págs. 504-507. DOI: [10.1126/science.1127647](https://doi.org/10.1126/science.1127647).
- [4] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni y Nassir Navab. «Autoencoders for Unsupervised Anomaly Segmentation in Brain MR Images: A Comparative Study». En: *Medical Image Analysis* 69

- (2021), pág. 101952. doi: [10.1016/j.media.2020.101952](https://doi.org/10.1016/j.media.2020.101952).
- [5] Diederik P. Kingma y Max Welling. «Auto-Encoding Variational Bayes». En: *International Conference on Learning Representations*. 2014. arXiv: [1312.6114](https://arxiv.org/abs/1312.6114).
- [6] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville y Yoshua Bengio. «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems*. Vol. 27. 2014, págs. 2672-2680.
- [7] Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Ursula Schmidt-Erfurth y Georg Langs. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». En: *Information Processing in Medical Imaging*. 2017, págs. 146-157. doi: [10.1007/978-3-319-59050-9_12](https://doi.org/10.1007/978-3-319-59050-9_12).
- [8] Samet Akçay, Amir Atapour-Abarghouei y Toby P. Breckon. «GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training». En: *Asian Conference on Computer Vision*. 2019, págs. 622-637. doi: [10.1007/978-3-030-20893-6_39](https://doi.org/10.1007/978-3-030-20893-6_39).
- [9] Haibo Zhang, Wenping Guo, Shiqing Zhang, Hongsheng Lu y Xiaoming Zhao. «Unsupervised Deep Anomaly Detection for Medical Images Using an Improved Adversarial Autoencoder». En: *Journal of Digital Imaging* 35.2 (2022), págs. 153-161. doi: [10.1007/s10278-021-00558-8](https://doi.org/10.1007/s10278-021-00558-8).
- [10] Xiaoyuan Guo, Judy Wawira Gichoya, Saptarshi Purkayastha e Imon Banerjee. *CVAD: A Generic Medical Anomaly Detector Based on Cascade VAE*. 2021. arXiv: [2110.15811](https://arxiv.org/abs/2110.15811).
- [11] Mariana-Iuliana Georgescu. «Masked Autoencoders for Unsupervised Anomaly Detection in Medical Images». En: *Procedia Computer Science: KES 2023*. 2023. arXiv: [2307.07534](https://arxiv.org/abs/2307.07534).
- [12] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár y Ross Girshick. «Masked Autoencoders Are Scalable Vision Learners». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, págs. 16000-16009.
- [13] Paul Bergmann, Michael Fauser, David Sattlegger y Carsten Steger. «MVTec AD: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, págs. 9592-9600. doi: [10.1109/CVPR.2019.00982](https://doi.org/10.1109/CVPR.2019.00982).
- [14] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang y Xingyu Li. «BMAD: Benchmarks for Medical Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2024, págs. 4042-4053.
- [15] George Shih et al. «Augmenting the National Institutes of Health Chest Radiograph Dataset with Expert Annotations of Possible Pneumonia». En: *Radiology: Artificial Intelligence* 1.1 (2019), e180041. doi: [10.1148/ryai.2019180041](https://doi.org/10.1148/ryai.2019180041).
- [16] Olaf Ronneberger, Philipp Fischer y Thomas Brox. «U-Net: Convolutional Networks for Biomedical Image Segmentation». En: *Medical Image Computing and Computer-Assisted Intervention* 9351 (2015), págs. 234-241. doi: [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).