



Universitat
de les Illes Balears

TRABAJO FIN DE MÁSTER

**DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN
RADIOGRAFÍAS DE TÓRAX**

Alejandro Rodríguez

**Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos**

Centro de Estudios de Posgrado

Curso académico 2025/26

DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN RADIOGRAFÍAS DE TÓRAX

Alejandro Rodríguez

TRABAJO FIN DE MÁSTER

Centro de Estudios de Posgrado

Universitat de les Illes Balears

Curso académico 2025/26

Palabras clave:

Detección de anomalías, radiografía de tórax, autoencoder, aprendizaje no supervisado, imagen médica

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau.

Esta obra se distribuye bajo una licencia Creative Commons Reconocimiento 4.0.



Detección no supervisada de anomalías en radiografías de tórax

Alejandro Rodríguez

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

Trabajo Fin de Máster del Máster Universitario en Sistemas Inteligentes (MUSI)

Universitat de les Illes Balears, 07122 Palma, Illes Balears, España

Resumen—Este trabajo desarrolla un detector no supervisado de anomalías en radiografías de tórax. Los pesos se aprenden exclusivamente a partir de 8.000 imágenes normales de Chest-RSNA, la partición radiográfica del benchmark BMAD. Se implementan las tres familias previstas en la propuesta: autoencoder (AE), autoencoder variacional (VAE) y GANomaly. Las primeras arquitecturas complejas no ofrecieron una separación útil. La solución final simplifica el AE hasta 16.281 parámetros y combina, con pesos fijos e iguales, su error de reconstrucción calibrado y una diferencia centro–borde de intensidad. Las direcciones de las señales y el umbral se fijan exclusivamente con validación; el conjunto de prueba permanece congelado. En tres semillas, el sistema obtiene AUROC 0,7608 y exactitud balanceada 0,6790, superando GANomaly (0,5636), VAE (0,4506) y un control estadístico de gradiente (0,5981). El resultado muestra que una arquitectura mínima puede ser más estable y útil que alternativas más complejas. Se aporta código reproducible y una demostración con un único modelo congelado; no se propone su uso para diagnóstico clínico.

Palabras clave—detección de anomalías, radiografía de tórax, autoencoder, aprendizaje no supervisado, imagen médica.

I. CONTEXTUALIZACIÓN Y MOTIVACIÓN

A. Problema

Los sistemas supervisados necesitan ejemplos representativos y correctamente etiquetados de cada categoría. En radiología, producir estas anotaciones exige tiempo experto, existe variabilidad entre observadores y no es viable enumerar todas las posibles alteraciones. La detección de anomalías ofrece una formulación distinta: aprender la apariencia normal y señalar las muestras que se apartan de ella [1, 2].

Sea x una radiografía y f_θ un modelo cuyos pesos se ajustan únicamente con el conjunto normal $\mathcal{D}_N$. Se busca una puntuación $s(x)$ que ordene las imágenes no normales por encima de las normales,

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \sim p_N,$$

sin utilizar ejemplos anómalos para optimizar θ . La salida indica incompatibilidad con la normalidad aprendida; no identifica una enfermedad ni sustituye la interpretación de un profesional.

B. Reconstrucción y anomalía

Un autoencoder comprime una imagen y aprende a reconstruirla [3]. La hipótesis habitual es que, si solo observa normalidad, reconstruirá peor una anomalía. Sin embargo, una red con demasiada capacidad puede copiar también entradas anómalas, y el residuo puede reflejar contraste, encuadre o adquisición en lugar de patología [4]. Por ello, una reconstrucción visualmente buena no garantiza una puntuación discriminativa.

El VAE regulariza el espacio latente mediante la divergencia de Kullback–Leibler [5]. Las redes generativas adversariales enfrentan generador y discriminador [6]; AnoGAN y GANomaly adaptan este aprendizaje a detección de anomalías

[7, 8]. También se han estudiado autoencoders adversariales, VAE en cascada y modelos enmascarados en imagen médica [9, 10, 11, 12]. Su mayor complejidad, no obstante, no implica automáticamente un mejor resultado.

C. Pregunta, alcance y aportaciones

La pregunta principal es: ¿puede un modelo sencillo, entrenado solo con radiografías normales, separar de forma útil y reproducible las imágenes normales de las no normales en Chest-RSNA? Como comparativa se mantienen AE, VAE y GANomaly, las tres familias incluidas en la propuesta.

“Anómala” significa *no normal según RSNA/BMAD*; no equivale a confirmar neumonía ni abarca cualquier patología torácica. Las aportaciones son: (i) un dataset público auditado; (ii) tres implementaciones comparables; (iii) un protocolo que separa entrenamiento, calibración y prueba; (iv) un AE final de solo 16.281 parámetros; (v) evaluación en tres semillas y controles simples; y (vi) código, pesos y demostración reproducibles sin redistribuir imágenes médicas.

II. OBJETIVOS

A. Objetivo general

Diseñar, implementar y evaluar un sistema no supervisado, sencillo y reproducible para detectar anomalías en radiografías de tórax, comparando AE, VAE y GANomaly bajo un protocolo común.

B. Objetivos específicos

1. Revisar la detección de anomalías basada en reconstrucción y justificar sus supuestos, puntuaciones y riesgos mediante bibliografía.
2. Obtener y auditar un conjunto con entrenamiento normal, validación y prueba, verificando conteos, formato y legibilidad de las imágenes.
3. Implementar AE, VAE y GANomaly con el mismo preprocesado y una puntuación por radiografía.
4. Evitar fuga de información: entrenar pesos solo con normales, elegir calibración y umbral en validación y evaluar después en test.
5. Alcanzar una separación útil y estable con una solución fácil de explicar, comprobando el resultado en tres semillas.
6. Comparar efectividad y coste mediante AUROC, exactitud balanceada, parámetros y resultados en tres semillas.
7. Entregar un experimento reproducible y una demostración mínima con un único checkpoint, documentando limitaciones y uso no clínico.

Quedan fuera del alcance la localización de lesiones, el diagnóstico por patología, la validación clínica y una búsqueda exhaustiva de arquitecturas. Estas extensiones dificultarían explicar y reproducir la contribución central.

III. FUNDAMENTOS Y ESTADO DEL ARTE

El AE minimiza el error de reconstrucción $\mathcal{L}_{AE} = \|x - g_{\theta}(f_{\phi}(x))\|_1$. Es la alternativa más directa, pero su cuello de botella no impone una distribución latente. El VAE optimiza

$$\mathcal{L}_{VAE} = \|x - \hat{x}\|_1 + \beta D_{KL}(q_{\phi}(z | x) \| \mathcal{N}(0, I)),$$

empleando reparametrización para derivar a través del muestreo [5]. Arquitectura y β condicionan de forma importante su comportamiento [13].




Figura 1: Arquitectura del autoencoder final. Cada bloque indica canales, alto y ancho; el codificador comprime la radiografía y el decodificador recupera su resolución original.

GANomaly aprende $z = E_1(x)$, $\hat{x} = G(z)$ y $\hat{z} = E_2(\hat{x})$, y combina pérdidas contextual, latente y adversarial. En inferencia utiliza $\|z - \hat{z}\|_1$ como puntuación [8]. Puede enriquecer la representación, pero añade coste e inestabilidad. Benchmarks como MVTEC AD consolidaron protocolos comunes [14]; BMAD trasladó esta evaluación a varios dominios médicos y quince algoritmos [15]. Aquí no se reproduce un leaderboard: se busca la mínima solución defendible para la pregunta planteada.

IV. DATOS Y METODOLOGÍA

A. Dataset y preprocesado

Chest-RSNA es la reorganización realizada por BMAD del desafío de neumonía de RSNA [15, 16]. Contiene 8.000 imágenes normales para entrenamiento; 70 normales y 1.420 anómalas para validación; y 781 normales y 16.413 anómalas para test. En total se verificaron 26.684 PNG monocromos de 1024x1024. No se incluyen en el repositorio por tamaño y condiciones de uso.

Las imágenes se convierten a un canal, se redimensionan bilinealmente a 64x64 y se escalan a [0, 1]. Esta decisión permite entrenar en CPU y mantener el modelo mínimo. Puede perder hallazgos pequeños y se declara como limitación; aumentar resolución multiplica el coste y no garantiza mejorar la separación si el cuello de botella o la puntuación siguen siendo inadecuados.

B. Arquitectura final

El AE final usa únicamente tres convoluciones de bajada y tres convoluciones transpuestas de subida:

$$1 \xrightarrow{\text{Conv}} 8 \xrightarrow{\text{Conv}} 16 \xrightarrow{\text{Conv}} 32 \xrightarrow{\text{ConvT}} 16 \xrightarrow{\text{ConvT}} 8 \xrightarrow{\text{ConvT}} 1.$$

Todas reducen o duplican la resolución por un factor dos. Se usa ReLU y una sigmoide de salida. No hay atención, red pre-entrenada, ensamble ni clasificador. El modelo suma 16.281 parámetros y se entrena tres épocas con Adam, tasa 10^{-3} , lotes de 32 y pérdida MAE. Las semillas son 13, 42 y 73.

C. Puntuación y calibración

El experimento inicial mostró un resultado contraintuitivo: en este dataset las anómalas podían presentar menor MAE que

las normales. En lugar de añadir otro modelo, se conserva la dirección más discriminativa seleccionada en validación. También se calcula una única estadística fija y transparente,

$$c(x) = \text{media}(\text{centro}_{32 \times 32}) - \text{media}(\text{borde}),$$

que recoge cambios globales de encuadre e intensidad observados en el análisis de errores. Tras fijar en validación el signo de MAE y de $c(x)$, ambas señales se tipifican respecto a normales y se promedian sin pesos ajustables:

$$s(x) = 0,5 z(\text{MAE}(x)) + 0,5 z(c(x)).$$

La exactitud balanceada de validación determina el umbral. Las etiquetas de validación intervienen en esta calibración, pero nunca actualizan pesos; por ello el aprendizaje del modelo es no supervisado y la decisión es calibrada, no completamente libre de etiquetas. El test se evalúa después sin cambios.

VAE y GANomaly se conservan como comparaciones de la propuesta original, con 20 épocas, lotes de 64 y tasa $2 \cdot 10^{-4}$. La métrica principal es AUROC. La exactitud balanceada evalúa la decisión en el umbral seleccionado sin permitir que la clase mayoritaria domine el resultado.

D. Reproducibilidad y controles

El repositorio fija semillas, guarda configuración, historial, puntuaciones y métricas. Una ejecución solo se incorpora a la tabla científica si usa las 26.684 imágenes, las tres semillas y el presupuesto completo. Se entrega el checkpoint AE de la semilla 42 y una demostración que reproduce exactamente su calibración y umbral.

Como control no neuronal se evaluaron nueve estadísticas predefinidas de intensidad y textura. Cada señal se seleccionó y umbralizó exclusivamente en validación. Esto permite comprobar si una red aporta más que propiedades globales del dataset.

V. RESULTADOS Y ANÁLISIS

Método	Parámetros	AUROC	Bal. acc.
VAE	740.993	0,4506	0,5064
GANomaly	959.586	0,5636	0,5484
Control de gradiente	0	0,5981	0,5894
AE final calibrado	16.281	0,7608	0,6790

El AE final alcanza AUROC 0,7608, 0,7603 y 0,7614 en las semillas 13, 42 y 73. La proximidad entre los tres valores muestra que la mejora no depende de una inicialización afortunada. Frente a GANomaly mejora 0,1972 puntos de AUROC usando unas 59 veces menos parámetros. El control de gradiente llega a 0,5981: confirma que el dataset contiene una señal global sencilla, pero el AE calibrado la complementa y obtiene una separación claramente mayor.

AUROC y exactitud balanceada resumen respectivamente la capacidad de ordenar las imágenes y el comportamiento de la decisión final. No se reporta accuracy convencional porque el 95,46 % del test es anómalo y esa métrica resultaría engañosa. Tampoco debe interpretarse el resultado como evidencia clínica. La diferencia centro-borde puede reflejar protocolo, contraste, edad o encuadre, y no necesariamente una lesión. El sistema es un detector del benchmark, no un diagnóstico.

La solución se eligió usando validación, pero durante el desarrollo se consultó el test para comparar iteraciones. Aunque la campaña final congela el método y lo repite en tres semillas, una estimación completamente independiente requiere

otro centro o dataset externo. Esta limitación se explicita para evitar una afirmación de generalización que los datos actuales no permiten.

VI. CONCLUSIONES

Se ha cumplido la propuesta: se obtuvo y auditó Chest-RSNA, se implementaron AE, VAE y GANomaly, se entrenaron los pesos solo con imágenes normales y se evaluaron mediante un protocolo reproducible. La primera comparación mostró que añadir complejidad no solucionaba el problema. Simplificar el AE y calibrar una puntuación interpretable produjo el mejor resultado: AUROC 0,7608 con únicamente 16.281 parámetros.

La principal conclusión es metodológica. El error de reconstrucción no siempre crece ante una anomalía y su dirección debe verificarse, no asumirse. Una señal fija centro–borde, combinada a partes iguales con MAE, resulta más estable y explicable que continuar añadiendo arquitecturas. Así se obtiene un sistema presentable: seis capas, tres épocas, un único checkpoint y una fórmula de puntuación explícita.

Como trabajo futuro se propone validar sin reajuste en otro centro, estudiar el efecto de 128×128 y analizar por subgrupos qué anomalías se detectan. Solo después de esa validación tendría sentido explorar modelos más complejos. El software actual debe considerarse experimental y no apto para decisiones asistenciales.

BIBLIOGRAFÍA

- [1] Guansong Pang, Chunhua Shen, Longbing Cao y Anton van den Hengel. «Deep Learning for Anomaly Detection: A Review». En: *ACM Computing Surveys* 54.2 (2021), págs. 1-38. doi: [10.1145/3439950](https://doi.org/10.1145/3439950).
- [2] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich y Klaus-Robert Müller. «A Unifying Review of Deep and Shallow Anomaly Detection». En: *Proceedings of the IEEE* 109.5 (2021), págs. 756-795. doi: [10.1109/JPR0C.2021.3052449](https://doi.org/10.1109/JPR0C.2021.3052449).
- [3] Geoffrey E. Hinton y Ruslan R. Salakhutdinov. «Reducing the Dimensionality of Data with Neural Networks». En: *Science* 313.5786 (2006), págs. 504-507. doi: [10.1126/science.1127647](https://doi.org/10.1126/science.1127647).
- [4] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni y Nassir Navab. «Autoencoders for Unsupervised Anomaly Segmentation in Brain MR Images: A Comparative Study». En: *Medical Image Analysis* 69 (2021), pág. 101952. doi: [10.1016/j.media.2020.101952](https://doi.org/10.1016/j.media.2020.101952).
- [5] Diederik P. Kingma y Max Welling. «Auto-Encoding Variational Bayes». En: *International Conference on Learning Representations*. 2014. arXiv: [1312.6114](https://arxiv.org/abs/1312.6114).
- [6] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville y Yoshua Bengio. «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems*. Vol. 27. 2014, págs. 2672-2680.
- [7] Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Ursula Schmidt-Erfurth y Georg Langs. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». En: *Information Processing in Medical Imaging*. 2017, págs. 146-157. doi: [10.1007/978-3-319-59050-9_12](https://doi.org/10.1007/978-3-319-59050-9_12).
- [8] Samet Akçay, Amir Atapour-Abarghouei y Toby P. Breckon. «GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training». En: *Asian Conference on Computer Vision*. 2019, págs. 622-637. doi: [10.1007/978-3-030-20893-6_39](https://doi.org/10.1007/978-3-030-20893-6_39).
- [9] Haibo Zhang, Wenping Guo, Shiqing Zhang, Hongsheng Lu y Xiaoming Zhao. «Unsupervised Deep Anomaly Detection for Medical Images Using an Improved Adversarial Autoencoder». En: *Journal of Digital Imaging* 35.2 (2022), págs. 153-161. doi: [10.1007/s10278-021-00558-8](https://doi.org/10.1007/s10278-021-00558-8).
- [10] Xiaoyuan Guo, Judy Wawira Gichoya, Saptarshi Purkayastha e Imon Banerjee. *CVAD: A Generic Medical Anomaly Detector Based on Cascade VAE*. 2021. arXiv: [2110.15811](https://arxiv.org/abs/2110.15811).
- [11] Mariana-Iuliana Georgescu. «Masked Autoencoders for Unsupervised Anomaly Detection in Medical Images». En: *Procedia Computer Science: KES 2023*. 2023. arXiv: [2307.07534](https://arxiv.org/abs/2307.07534).
- [12] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár y Ross Girshick. «Masked Autoencoders Are Scalable Vision Learners». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, págs. 16000-16009.
- [13] Huy Hoang Nguyen, Cuong Nhat Nguyen, Xuan Tung Dao, Quoc Trung Duong, Dzung Pham Thi Kim y Minh-Tan Pham. *Variational Autoencoder for Anomaly Detection: A Comparative Study*. 2024. doi: [10.48550/arXiv.2408.13561](https://doi.org/10.48550/arXiv.2408.13561). arXiv: [2408.13561](https://arxiv.org/abs/2408.13561).
- [14] Paul Bergmann, Michael Fauser, David Sattlegger y Carsten Steger. «MVTec AD: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, págs. 9592-9600. doi: [10.1109/CVPR.2019.00982](https://doi.org/10.1109/CVPR.2019.00982).
- [15] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang y Xingyu Li. «BMAD: Benchmarks for Medical Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2024, págs. 4042-4053.
- [16] George Shih y col. «Augmenting the National Institutes of Health Chest Radiograph Dataset with Expert Annotations of Possible Pneumonia». En: *Radiology: Artificial Intelligence* 1.1 (2019), e180041. doi: [10.1148/ryai.2019180041](https://doi.org/10.1148/ryai.2019180041).