



Universitat
de les Illes Balears

TRABAJO FIN DE MÁSTER

**DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN
CORTES CEREBRALES MEDIANTE UN DAE**

Alejandro Rodríguez

**Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos**

Centro de Estudios de Posgrado

Curso académico 2025/26

DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN CORTES CEREBRALES MEDIANTE UN DAE

Alejandro Rodríguez

TRABAJO FIN DE MÁSTER

**Centro de Estudios de Posgrado
Universitat de les Illes Balears**

Curso académico 2025/26

Palabras clave:

Detección de anomalías, resonancia magnética cerebral, denoising autoencoder, aprendizaje no supervisado, imagen médica, BraTS2021

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau.

Esta obra se distribuye bajo una licencia Creative Commons Reconocimiento 4.0.



Detección no supervisada de anomalías en cortes cerebrales mediante un DAE

Alejandro Rodríguez

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

Trabajo Fin de Máster del Máster Universitario en Sistemas Inteligentes (MUSI)

Universitat de les Illes Balears, Palma, España

Resumen—Este trabajo estudia la detección no supervisada de anomalías en cortes cerebrales FLAIR. Se entrena exclusivamente con 7.500 imágenes normales un denoising autoencoder (DAE) inspirado en Kascenas, Pugeault y O’Neil. El modelo es una U-Net 2D de tres reducciones, conexiones de salto y 8.558.721 parámetros. Durante el entrenamiento se añade ruido gaussiano grueso al primer plano y se aprende a recuperar la imagen limpia. En inferencia, el error absoluto de reconstrucción, enmascarado y filtrado mediante una mediana 5×5 , produce la puntuación por imagen. El umbral se estima en validación y se aplica una sola vez en test. La campaña final contempla tres semillas y aproximadamente 67.200 actualizaciones por ejecución. El sistema es experimental y no está destinado al diagnóstico clínico.

Palabras clave—detección de anomalías, resonancia magnética cerebral, denoising autoencoder, aprendizaje no supervisado, BraTS2021.

I. CONTEXTUALIZACIÓN Y MOTIVACIÓN

A. Problema

Los métodos supervisados requieren ejemplos representativos y anotados de cada categoría. En radiología, estas anotaciones consumen tiempo experto, presentan variabilidad entre observadores y no abarcan todas las alteraciones posibles. La detección de anomalías plantea aprender una distribución de normalidad p_N y asignar una puntuación $s(x)$ mayor a las observaciones que se apartan de ella [9, 10]:

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N.$$

La salida expresa incompatibilidad con la normalidad aprendida; no identifica una enfermedad concreta ni sustituye la interpretación profesional.

B. Hipótesis de reconstrucción

Un autoencoder aprende a reconstruir su entrada [6]. Si sus pesos solo se ajustan con imágenes normales, se espera que represente bien la anatomía habitual y produzca residuos mayores ante patrones no observados. Sin embargo, un cuello de botella demasiado restrictivo deteriora también la reconstrucción normal, mientras que un modelo que copie la entrada puede reconstruir anomalías [2]. Kascenas et al. [7] proponen evitar el cuello de botella restrictivo y entrenar una U-Net para eliminar ruido grueso. La naturaleza espacial del ruido obliga a aprender patrones anatómicos, en lugar de la identidad píxel a píxel.

C. Pregunta y aportaciones

La pregunta de investigación es: *¿puede un DAE entrenado solo con cortes FLAIR normales separar de forma útil y reproducible los cortes normales de los anómalos en BraTS2021_slice?* Las aportaciones son: una adaptación unimodal y por imagen del método de Kascenas et al.; un protocolo sin uso del test para seleccionar pesos o umbral; una implementación reproducible con tres semillas; y un análisis explícito de las diferencias respecto del trabajo original.

II. OBJETIVOS

El objetivo general es diseñar, implementar y evaluar un detector no supervisado basado en reconstrucción. Los objetivos específicos son:

1. revisar la detección de anomalías mediante autoencoders;
2. auditar datos, particiones y preprocesado;
3. implementar el DAE, el ruido grueso y el score por imagen;
4. entrenar los pesos solo con normales y calibrar únicamente en validación;
5. medir AUROC y exactitud balanceada sobre test con tres semillas; y
6. conservar configuración, pesos, scores e historial para reproducibilidad.

III. FUNDAMENTOS Y ESTADO DEL ARTE

Los autoencoders convencionales comprimen la entrada y minimizan una distancia de reconstrucción. Los VAE regulan el espacio latente [8]; los métodos adversariales incorporan generadores y discriminadores [4]; y los masked autoencoders predicen regiones ocultas [5, 3]. Estas alternativas añaden hipótesis y complejidad. En imagen cerebral, las reconstrucciones pueden ser borrosas o producir falsos positivos en tejido sano [2].

El método de referencia [7] utiliza una U-Net sin cuello de botella vectorial. Su contribución principal es un ruido gaussiano muestreado a baja resolución e interpolado: el ruido píxel a píxel resultó menos eficaz, mientras que 16×16 con $\sigma = 0,2$ obtuvo el mejor compromiso de su ablación. Este trabajo conserva ese principio y lo adapta al formato de clasificación de BMAD [1].

IV. DATOS Y PROTOCOLO

A. Dataset y preprocesado

Se emplea BraTS2021_slice, una partición de BMAD derivada de BraTS2021. Cada ejemplo es un PNG FLAIR monocromo. El conjunto contiene 7.500 cortes normales para entrenamiento, 39 normales y 44 anómalos para validación, y 640 normales y 3.075 anómalos para test. La etiqueta es por corte; no se dispone de la máscara tumoral en el flujo utilizado.

Las imágenes se convierten a escala de grises, se redimensionan de 240×240 a 128×128 mediante interpolación bilineal y se dividen por 255. No se aplica data augmentation geométrica. El fondo se identifica como $x \leq 0,01$, umbral que evita incluir valores residuales de la interpolación.

B. Separación de responsabilidades

Los pesos se optimizan con *train/good*. La pérdida de validación se calcula con *valid/good* y selecciona la mejor época. Después, las dos clases de validación determinan el umbral. El test solo interviene en el cálculo final de métricas. Por tanto, las etiquetas no actualizan los pesos, aunque la decisión binaria sí es calibrada de forma supervisada en validación.

V. MÉTODO PROPUESTO

A. Generación de ruido y función objetivo

Para cada lote limpio x se muestrea $n_s \sim \mathcal{N}(0, I)$ a resolución 16×16 , se interpola bilinealmente a 128×128 y se traslada de forma circular una cantidad aleatoria. Con $M = \mathbb{I}(x > 0,01)$ y $\sigma = 0,2$:

$$\tilde{x} = x + \sigma M \odot \text{roll}(\text{up}(n_s)).$$

No se recorta $\tilde{x}$ a $[0, 1]$: el ruido es una corrupción sintética que el modelo debe retirar. La salida $\hat{x} = f_\theta(\tilde{x})$ se optimiza mediante MSE de primer plano:

$$\mathcal{L}(\theta) = \frac{\sum M \odot (\hat{x} - x)^2}{\max(\sum M, 1)}.$$

B. Arquitectura DAE

La red es una U-Net 2D con cuatro bloques de resolución y tres operaciones de pooling. Cada bloque aplica dos veces convolución 3×3 , SiLU y GroupNorm con ocho grupos. El codificador usa 64, 128, 256 y 512 canales. El decoder interpola bilinealmente, aplica una convolución y concatena la activación del encoder de igual escala. Una convolución 1×1 genera el canal FLAIR sin sigmoide de salida. Con la configuración base suma 8.558.721 parámetros.

C. Puntuación de anomalía

En inferencia se introduce la imagen limpia; no se añade ruido. Primero se erosiona la máscara mediante average pooling 5×5 para reducir errores en el borde del cráneo. Se calcula el residuo absoluto y se aplica un filtro de mediana 5×5 :

$$A(x) = f_{\text{med},5}(\tilde{M} \odot |x - f_\theta(x)|).$$

Como BMAD proporciona una etiqueta por corte, el mapa se reduce a $s(x) = \max_{i,j} A(x)_{ij}$. El máximo busca una región local intensa y la mediana impide que un único píxel aislado domine la decisión.

D. Optimización

Se usa Adam con AMSGrad, $\text{lr} = 10^{-4}$, weight decay 10^{-5} y batch 16. El scheduler coseno se actualiza por lote con $T_{\text{máx}} = 100$, equivalente a un ciclo máximo-máximo de 200 actualizaciones. Con 7.500 imágenes, 143 épocas suponen aproximadamente 67.067 actualizaciones, próximas a las 67.200 del paper. Se ejecutan las semillas 13, 42 y 73; se fija el comportamiento determinista de cuDNN y se guarda la época con menor MSE normal de validación.

E. Diferencias respecto del paper

VI. EVALUACIÓN Y REPRODUCIBILIDAD

El AUROC mide la probabilidad de ordenar un corte anómalo por encima de uno normal y no depende de un umbral. La exactitud balanceada es la media de sensibilidad y especificidad, adecuada porque el test está desbalanceado. El umbral se escoge en validación maximizando $TPR - FPR$ y se aplica sin cambios a test. Cada ejecución guarda `model.pt`, `metrics.json`, los CSV de scores y una rejilla de reconstrucciones. Se informa media y desviación estándar de las tres semillas.

VII. RESULTADOS PROVISIONALES

Advertencia. Los valores de esta sección son simulados para cerrar la maquetación mientras finaliza Colab. No son resultados experimentales y deben reemplazarse por los tres `metrics.json` definitivos.

Semilla	AUROC test	Balanced accuracy test
13	0,876	0,798
42	0,899	0,827
73	0,886	0,811
Media $\pm$ d.t.	0,887 $\pm$ 0,011	0,812 $\pm$ 0,014

Estos valores ficticios únicamente reservan espacio y muestran cómo se presentará la variabilidad entre semillas. No se interpretan ni se comparan con el estado del arte. La ejecución local reducida tampoco se incorpora: utilizó 128 imágenes, cinco épocas y 32 ejemplos por clase, por lo que solo constituye una prueba funcional.

VIII. LIMITACIONES Y CONCLUSIONES

La adaptación conserva la aportación central del paper —aprender a retirar ruido espacial grueso con una U-Net entrenada solo en normalidad—, pero cambia el problema científico. Se pierde la información multimodal y tridimensional, y una etiqueta por corte no permite medir localización tumoral. El máximo del mapa es interpretable, aunque puede ser sensible a artefactos locales; la erosión de máscara y la mediana mitigan, pero no eliminan, esta limitación. La validación contiene pocas imágenes y el conjunto procede de un benchmark, por lo que no demuestra generalización clínica ni externa.

La contribución del trabajo es una línea base DAE compacta en concepto, reproducible y metodológicamente separada entre entrenamiento, calibración y test. Las conclusiones cuantitativas se incorporarán solo tras completar las tres ejecuciones de Colab. Como trabajo futuro se propone evaluar mapas con máscaras de lesión, recuperar las cuatro modalidades, analizar resultados por paciente y validar en datos de otros centros. El software es experimental y no apto para decisiones asistenciales.

REFERENCIAS

- [1] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang, and Xingyu Li. BMAD: Benchmarks for medical anomaly detection. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 4042–4053, 2024.
- [2] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni, and Nassir Navab. Autoencoders for unsupervised anomaly segmentation in brain MR images: A comparative study. *Medical Image Analysis*, 69:101952, 2021.
- [3] Mariana-Iuliana Georgescu. Masked autoencoders for unsupervised anomaly detection in medical images. In *Procedia Computer Science: KES 2023*, 2023.
- [4] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, volume 27, pages 2672–2680, 2014.
- [5] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.




Figura 1: Arquitectura del DAE para una entrada $1 \times 128 \times 128$. El encoder reduce mediante average pooling; el decoder usa interpolación bilineal seguida de convolución. Las conexiones de salto conservan el detalle espacial.

Aspecto	Kascenas et al.	Adaptación de este trabajo
Entrada	Cuatro modalidades: T1, T1Gd, T2 y FLAIR	Un único canal FLAIR, acorde con los PNG de BMAD
Tarea	Segmentación y score por píxel	Clasificación por corte mediante el máximo del mapa filtrado
Convolución	Weight standardization y padding por reflexión	Conv2d estándar, padding cero y bias omitido junto a GroupNorm
Ampliación	Convolución transpuesta 2×2	Interpolación bilineal y convolución 3×3 , para una subida suave
Normalización	Grupos calculados según los canales	Ocho grupos fijos, válidos para todos los anchos usados
Intensidad	División por percentil 99 de cada modalidad y volumen	Conversión directa del PNG a $[0, 1]$
Evaluación	AUPRC y Dice píxel a píxel; componentes conexas 3D opcionales	AUROC y balanced accuracy por corte; sin postprocesado 3D
Calibración	Umbral óptimo de Dice explorado sobre test	Umbral de Youden en validación, congelado antes del test

Cuadro 1: Cambios necesarios para adaptar el método de referencia al dato y al objetivo de este proyecto.




Figura 2: Reconstrucciones obtenidas en la ejecución local reducida. Arriba: originales; abajo: reconstrucciones. La figura verifica el flujo, pero no pertenece a la campaña científica final.

- [6] Geoffrey E. Hinton and Ruslan R. Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006.
- [7] Antanas Kascenas, Nicolas Pugeault, and Alison Q. O’Neil. Denoising autoencoders for unsupervised anomaly detection in brain MRI. In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 653–664, 2022.
- [8] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. In *International Conference on Learning Representations*, 2014.
- [9] Guansong Pang, Chunhua Shen, Longbing Cao, and Anton van den Hengel. Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2):1–38, 2021.
- [10] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, and Klaus-Robert Müller. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109(5):756–795, 2021.