



Universitat
de les Illes Balears

TRABAJO FIN DE MÁSTER

**DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN
CORTES CEREBRALES MEDIANTE UN DAE**

Alejandro Rodríguez

**Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos**

Centro de Estudios de Posgrado

Curso académico 2025/26

DETECCIÓN NO SUPERVISADA DE ANOMALÍAS EN CORTES CEREBRALES MEDIANTE UN DAE

Alejandro Rodríguez

TRABAJO FIN DE MÁSTER

**Centro de Estudios de Posgrado
Universitat de les Illes Balears**

Curso académico 2025/26

Palabras clave:

Detección de anomalías, resonancia magnética cerebral, denoising autoencoder, aprendizaje no supervisado, imagen médica, BraTS2021

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau.

Esta obra se distribuye bajo una licencia Creative Commons Reconocimiento 4.0.



Detección no supervisada de anomalías en cortes cerebrales mediante un DAE

Alejandro Rodríguez

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

Trabajo Fin de Máster del Máster Universitario en Sistemas Inteligentes (MUSI)
Universitat de les Illes Balears, Palma, España

Resumen—Este trabajo estudia la detección no supervisada de anomalías en cortes cerebrales FLAIR mediante un denoising autoencoder (DAE) inspirado en Kascenas, Pugeault y O’Neil. Los pesos del modelo se aprenden exclusivamente con 7.500 imágenes normales. La red es una U-Net 2D de tres reducciones, conexiones de salto y 8.558.721 parámetros. Durante el entrenamiento se añade ruido gaussiano grueso únicamente al primer plano y el modelo aprende a recuperar la imagen limpia mediante MSE. En inferencia se usa la imagen sin corromper: el error absoluto de reconstrucción se enmascara, se filtra con una mediana 5×5 y se reduce al máximo espacial para obtener una puntuación por corte. El umbral se calibra en validación mediante el índice de Youden y se mantiene fijo al evaluar test. La configuración reproducible actual utiliza imágenes 128×128 , batch 16, Adam con AMSGrad, 50 épocas y semilla 42. El sistema es experimental y no está destinado al diagnóstico clínico.

Palabras clave—detección de anomalías, resonancia magnética cerebral, denoising autoencoder, aprendizaje no supervisado, BraTS2021.

I. CONTEXTUALIZACIÓN Y MOTIVACIÓN

A. Problema

Los métodos supervisados requieren ejemplos representativos y anotados de las categorías que se desean reconocer. En imagen médica, obtener estas anotaciones requiere tiempo experto, puede presentar variabilidad entre observadores y no garantiza cubrir todas las alteraciones posibles. La detección de anomalías plantea una pregunta diferente: aprender la distribución de normalidad p_N y asignar una puntuación $s(x)$ mayor a las observaciones que se apartan de ella [9, 10]:

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N.$$

La salida del sistema expresa incompatibilidad con la normalidad aprendida. No identifica una enfermedad concreta ni sustituye la interpretación clínica.

B. Hipótesis de reconstrucción

Un autoencoder aprende a reconstruir su entrada [6]. Si sus pesos se ajustan solo con imágenes normales, una hipótesis habitual es que represente mejor la anatomía observada durante entrenamiento y produzca residuos mayores ante patrones distintos. Sin embargo, un autoencoder demasiado restrictivo puede reconstruir mal también tejido normal, mientras que uno con demasiada capacidad puede aproximarse a la identidad y reconstruir anomalías [2]. Kascenas et al. [7] proponen entrenar una U-Net para eliminar ruido espacial grueso. El objetivo deja de ser copiar la entrada y pasa a ser recuperar una imagen normal limpia desde una versión artificialmente corrompida.

C. Pregunta de investigación y aportación

La pregunta de investigación es: ¿puede un DAE entrenado solo con cortes FLAIR normales separar cortes normales de anómalos en BraTS2021_slice mediante el error de reconstrucción? Este trabajo adapta el método de Kascenas et al. al

formato disponible en BMAD: una única modalidad FLAIR, imágenes 2D independientes y una etiqueta global por corte. Se mantiene separado el aprendizaje de pesos, la selección de época, la calibración del umbral y la evaluación final.

II. OBJETIVOS

El objetivo general es diseñar, implementar y evaluar un detector de anomalías basado en reconstrucción. Los objetivos específicos son:

1. revisar el uso de autoencoders para detección de anomalías;
2. auditar el dataset, sus particiones y su preprocesado;
3. implementar un DAE tipo U-Net y la corrupción por ruido grueso;
4. entrenar los pesos exclusivamente con imágenes normales;
5. definir una puntuación escalar por corte a partir del residuo;
6. calibrar el umbral únicamente con validación etiquetada;
7. medir AUROC y exactitud balanceada en test; y
8. conservar configuración, pesos, scores e historial para reproducibilidad.

III. FUNDAMENTOS Y ESTADO DEL ARTE

Los autoencoders convencionales comprimen la entrada y minimizan una distancia de reconstrucción. Los VAE regularizan explícitamente el espacio latente [8]; los métodos adversariales incorporan generadores y discriminadores [4]; y los masked autoencoders predicen regiones ocultas [5, 3]. Estas familias son relevantes, pero añaden hipótesis y complejidad que no son necesarias para la línea base estudiada aquí. En imagen cerebral, además, la reconstrucción puede ser borrosa o producir falsos positivos en tejido sano [2].

El método de referencia [7] utiliza una U-Net sin cuello de botella vectorial restrictivo. Una de sus ideas centrales es generar ruido gaussiano a baja resolución e interpolarlo antes de sumarlo a la imagen. De esta forma la corrupción presenta estructura espacial de baja frecuencia y la red necesita contexto anatómico para retirarla. Este trabajo conserva esa idea y utiliza los valores principales 16×16 y $\sigma = 0,2$, adaptando la salida al problema de clasificación por corte de BMAD [1].

IV. DATOS Y PROTOCOLO

A. Dataset

Se emplea BraTS2021_slice, una partición de BMAD derivada de BraTS2021. Cada ejemplo utilizado es un PNG FLAIR monocromo. La estructura que consume el código es train/good, valid/good, valid/Ungood, test/good y test/Ungood. El conjunto contiene 7.500 cortes normales para entrenamiento, 39 normales y 44 anómalos para validación, y 640 normales y 3.075 anómalos para test. El flujo de este proyecto utiliza una etiqueta por corte y no una máscara tumoral.

B. Preprocesado

Cada PNG se abre con PIL, se convierte a escala de grises y se redimensiona a 128×128 mediante interpolación bilineal. Los valores se convierten a float32 y se dividen por 255, por lo que la entrada queda en el rango $[0, 1]$. Finalmente se añade la dimensión de canal para obtener tensores $1 \times 128 \times 128$. No se aplica data augmentation geométrica.

El fondo se identifica mediante $x \leq 0,01$. El umbral no representa una propiedad clínica; es una decisión de preprocesado para excluir el fondo negro y pequeños valores residuales generados por la interpolación.

C. Separación de train, validación y test

Los pesos se optimizan únicamente con *train/good*. La pérdida de validación se calcula únicamente con *valid/good* y sirve para seleccionar la época con menor error de reconstrucción normal. Después, normales y anómalas de validación se usan para calibrar el umbral de decisión. El test interviene solo en el cálculo final de métricas. Por tanto, las etiquetas no actualizan los pesos del DAE, aunque la decisión binaria sí se calibra de forma supervisada en validación.

V. MÉTODO PROPUESTO

A. Generación de ruido

Para cada lote limpio x se muestrea ruido $n_s \sim \mathcal{N}(0, I)$ a resolución 16×16 . El ruido se interpola bilinealmente hasta 128×128 y se desplaza circularmente una cantidad aleatoria en los dos ejes. Con $M = \mathbb{I}(x > 0,01)$ y $\sigma = 0,2$:

$$\tilde{x} = x + \sigma M \odot \text{roll}(\text{up}(n_s)).$$

La máscara hace que la corrupción afecte al primer plano cerebral y no al fondo. No se recorta $\tilde{x}$ a $[0, 1]$: durante entrenamiento es una entrada sintéticamente corrompida cuya función es obligar a la red a aprender la restauración de una imagen limpia.

B. Función objetivo

El modelo produce $\hat{x} = f_\theta(\tilde{x})$. La pérdida es una MSE calculada exclusivamente en el primer plano:

$$\mathcal{L}(\theta) = \frac{\sum M \odot (\hat{x} - x)^2}{\max(\sum M, 1)}.$$

Excluir el fondo evita que una gran región negra, trivial de reconstruir, domine la función objetivo. El cuadrado penaliza con mayor intensidad los errores de reconstrucción grandes y proporciona una función diferenciable para actualizar los parámetros mediante descenso por gradiente.

C. Arquitectura DAE

La red es una U-Net 2D con cuatro bloques de resolución y tres operaciones de reducción. Cada ConvBlock aplica dos secuencias de convolución 3×3 , SiLU y GroupNorm con ocho grupos. El codificador utiliza 64, 128, 256 y 512 canales. Entre bloques se aplica AvgPool2d(2), de modo que la resolución evoluciona $128 \rightarrow 64 \rightarrow 32 \rightarrow 16$.

El decoder realiza tres subidas. Cada una interpola bilinealmente por un factor 2, aplica una convolución 3×3 y concatena la activación del encoder de la misma escala mediante una conexión de salto. El último bloque conserva 64 canales y una convolución 1×1 los proyecta a un único canal FLAIR. No se usa sigmoide final: el problema se formula como regresión de intensidades y la salida permanece lineal durante el entrenamiento. Con base_ch=64, la arquitectura contiene exactamente 8.558.721 parámetros entrenables.

D. Justificación de las decisiones arquitectónicas

Las convoluciones 3×3 explotan la estructura espacial de la imagen y mantienen la resolución gracias a padding=1. La duplicación progresiva de canales permite aumentar la capacidad representacional mientras disminuye la resolución espacial. SiLU aporta una no linealidad suave. GroupNorm no depende de estadísticas entre ejemplos del minibatch y resulta adecuada con batches moderados o pequeños. El average pooling produce una reducción suave de la resolución. Las conexiones de salto recuperan detalle espacial necesario para reconstrucción, mientras que el entrenamiento de denoising reduce el riesgo de que la red aprenda únicamente una identidad píxel a píxel.

Se usa interpolación bilineal seguida de convolución para separar explícitamente la ampliación espacial del aprendizaje de filtros. Las convoluciones que van seguidas de GroupNorm omiten el bias por ser redundante con el desplazamiento aprendido por la normalización.

E. Optimización

La configuración actual usa batch 16, Adam con AMS-Grad, learning rate 10^{-4} y weight decay 10^{-5} . El scheduler es CosineAnnealingLR con $T_{\text{máx}} = 100$ y se actualiza después de cada lote. Por tanto, $T_{\text{máx}}$ está expresado en actualizaciones del optimizador, no en épocas. Con 7.500 imágenes, batch 16 y 50 épocas se realizan aproximadamente $[7500/16] \times 50 = 23.450$ actualizaciones.

La ejecución reproducible predeterminada utiliza 50 épocas y semilla 42. Se fijan las semillas de Python, NumPy y PyTorch; en CUDA se fijan también todas las semillas y se configura cuDNN en modo determinista. En cada época se calcula la MSE de validación sobre imágenes normales y se conserva en memoria el estado con menor valor. Tras terminar las 50 épocas se recargan esos pesos, por lo que la época elegida puede ser anterior a la última.

F. Puntuación de anomalía

En inferencia se introduce la imagen limpia x ; no se añade ruido. El modelo produce $f_\theta(x)$ y se calcula el residuo absoluto. Para reducir respuestas en el borde del cerebro, la máscara binaria se promedia localmente con una ventana 5×5 y solo se conservan posiciones con promedio superior a 0,95. Después se aplica un filtro de mediana 5×5 al mapa de error:

$$A(x) = f_{\text{med},5}(\tilde{M} \odot |x - f_\theta(x)|).$$

La mediana reduce el efecto de valores aislados. Dado que BMAD proporciona una etiqueta global por corte, el mapa se reduce a un único valor:

$$s(x) = \max_{i,j} A(x)_{ij}.$$

El máximo busca detectar la presencia de una región local con error elevado. El filtrado previo es importante porque un máximo directo sería muy sensible a un único píxel espurio.

G. Calibración del umbral

A partir de los scores y etiquetas de validación se construye la curva ROC. El umbral elegido maximiza

$$J = TPR - FPR,$$

el índice de Youden. Como $1 - FPR$ es la especificidad, maximizar J busca un compromiso entre sensibilidad y especificidad. El umbral seleccionado en validación se congela y se aplica posteriormente al test sin reajustes.




Figura 1: Arquitectura del DAE para una entrada $1 \times 128 \times 128$. El encoder reduce mediante average pooling; el decoder usa interpolación bilineal seguida de convolución.

H. Diferencias respecto del método de referencia

VI. EVALUACIÓN

A. AUROC

El AUROC resume la capacidad del score para ordenar imágenes anómalas por encima de normales sin fijar un umbral concreto. Puede interpretarse como la probabilidad de que una imagen anómala elegida al azar reciba mayor puntuación que una normal elegida al azar. Un valor de 0,5 corresponde a una separación aleatoria y 1 a una ordenación perfecta.

B. Exactitud balanceada

Una vez fijado el umbral se generan predicciones binarias. Debido al fuerte desbalance del test, se utiliza exactitud balanceada en lugar de accuracy convencional:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Así, sensibilidad y especificidad contribuyen con el mismo peso aunque haya muchas más imágenes anómalas que normales.

VII. REPRODUCIBILIDAD E IMPLEMENTACIÓN

La implementación se divide en cuatro responsabilidades. `data.py` localiza las imágenes, crea los datasets y realiza el preprocesado; `dae.py` define la arquitectura; `experiment.py` contiene entrenamiento, validación, scoring, selección de umbral y métricas; y `train.py` expone la interfaz de línea de comandos.

Cada ejecución completa guarda `model.pt`, `metrics.json`, `validation_scores.csv`, `test_scores.csv` y una imagen de reconstrucciones. `metrics.json` conserva la configuración, el historial de pérdidas, la época seleccionada, el umbral y las métricas. El notebook de Colab clona explícitamente la rama `brain`, comprueba la disponibilidad de GPU, descarga los datos, ejecuta un smoke test y lanza la configuración completa de 50 épocas con semilla 42.

VIII. RESULTADOS

La ejecución científica completa se realizó durante 50 épocas con semilla 42, batch de 16 imágenes, tasa de aprendizaje 10^{-4} y ruido gaussiano de $\sigma = 0,2$ generado a resolución 16×16 . El entrenamiento duró 5.706 segundos (1,58 horas) en GPU. La época 47 obtuvo el menor error de validación normal, 0,00298, y se empleó para generar los scores definitivos. El umbral de Youden calibrado exclusivamente en validación fue 0,18611.

En test se clasificaron correctamente 2.832 de 3.075 cortes anómalos y 575 de 640 cortes normales: 243 fueron falsos negativos y 65 falsos positivos. Esto equivale a una sensibilidad de 0,9210 y una especificidad de 0,8984. El AUROC de 0,9633 indica una separación elevada entre las distribuciones de scores; la balanced accuracy confirma que el resultado no se debe al desbalance de clases.

La Figura 2 muestra ejemplos producidos por el modelo seleccionado. Las reconstrucciones preservan la anatomía global mientras que el mapa de error resalta las discrepancias

locales empleadas para calcular el score de anomalía.




Figura 2: Ejemplos de entrada, reconstrucción y error de la ejecución completa con semilla 42.

IX. LIMITACIONES

El proyecto trabaja con una sola modalidad FLAIR y cortes 2D independientes, por lo que pierde información multimodal y tridimensional disponible en estudios de RM completos. La etiqueta por corte no permite evaluar directamente la calidad de localización de una lesión. El score basado en el máximo puede reaccionar a artefactos locales; la erosión implícita de la máscara y el filtro de mediana reducen este efecto, pero no lo eliminan. La validación contiene pocas imágenes, lo que puede hacer inestable la estimación del umbral. Finalmente, un benchmark no demuestra generalización a otros centros, poblaciones o escáneres.

Otra limitación metodológica es que el sistema es no supervisado respecto al aprendizaje de los pesos, pero no completamente libre de etiquetas: el umbral de clasificación utiliza las etiquetas de validación. Esta separación debe quedar explícita para interpretar correctamente el alcance del método.

X. CONCLUSIONES Y TRABAJO FUTURO

Se ha implementado una adaptación unimodal y por corte de un denoising autoencoder para detección de anomalías cerebrales. El modelo aprende exclusivamente de imágenes normales, utiliza ruido espacial grueso como tarea de restauración y convierte el error de reconstrucción en un score de anomalía filtrado. El protocolo mantiene separados entrenamiento, selección de pesos, calibración y test, y conserva los artefactos necesarios para reproducir una ejecución.

La contribución principal no es un nuevo modelo clínico, sino una línea base reproducible y explicable que adapta el principio de Kascenas et al. al formato 2D FLAIR de BMAD. En la ejecución completa alcanzó un AUROC de 0,9633 y una balanced accuracy de 0,9097 en test. Como trabajo futuro se propone estudiar varias semillas, evaluar la sensibilidad a hiperparámetros como σ , resolución del ruido y tamaño del filtro, recuperar información multimodal y tridimensional, utilizar máscaras de lesión cuando estén disponibles y validar externamente en datos de otros centros. El software es experimental y no es apto para decisiones asistenciales.

REFERENCIAS

- [1] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang, and Xingyu Li. BMAD: Benchmarks for medical anomaly detection. In *IEEE/CVF Conference*

Aspecto	Kascenas et al.	Adaptación de este trabajo
Entrada	Cuatro modalidades: T1, T1Gd, T2 y FLAIR	Un único canal FLAIR, acorde con los PNG de BMAD
Tarea	Detección/localización basada en mapa de anomalía	Clasificación por corte mediante un score escalar
Convolución	Implementación específica del trabajo de referencia	Conv2d estándar con GroupNorm
Ampliación	Arquitectura original del paper	Interpolación bilineal seguida de convolución 3×3
Normalización	Configuración del método original	Ocho grupos fijos, compatibles con 64, 128, 256 y 512 canales
Intensidad	Preprocesado multimodal del trabajo original	PNG FLAIR convertido directamente a $[0, 1]$
Evaluación	Evaluación espacial propia de la tarea original	AUROC y balanced accuracy por corte
Calibración	Protocolo del trabajo original	Youden en validación, congelado antes de test

Cuadro 1: Principales adaptaciones necesarias para trabajar con el formato de BraTS2021_slice utilizado en este proyecto.

Partición	AUROC	Balanced accuracy
Validación (83 cortes)	0,9452	0,8820
Test (3.715 cortes)	0,9633	0,9097

Cuadro 2: Resultados de la ejecución completa del DAE con semilla 42.

[10] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, and Klaus-Robert Müller. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109(5):756–795, 2021.

on *Computer Vision and Pattern Recognition Workshops*, pages 4042–4053, 2024.

- [2] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni, and Nassir Navab. Autoencoders for unsupervised anomaly segmentation in brain MR images: A comparative study. *Medical Image Analysis*, 69:101952, 2021.
- [3] Mariana-Iuliana Georgescu. Masked autoencoders for unsupervised anomaly detection in medical images. In *Procedia Computer Science: KES 2023*, 2023.
- [4] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, volume 27, pages 2672–2680, 2014.
- [5] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009, 2022.
- [6] Geoffrey E. Hinton and Ruslan R. Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786):504–507, 2006.
- [7] Antanas Kascenas, Nicolas Pugeault, and Alison Q. O’Neil. Denoising autoencoders for unsupervised anomaly detection in brain MRI. In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 653–664, 2022.
- [8] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. In *International Conference on Learning Representations*, 2014.
- [9] Guansong Pang, Chunhua Shen, Longbing Cao, and Anton van den Hengel. Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2):1–38, 2021.