

Alejandro Rodríguez

Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos
Universitat de les Illes Balears

Curso 2025/26



Universitat
de les Illes Balears

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

- 1 Problema y objetivo
- 2 Datos y preprocesado
- 3 Del autoencoder al DAE
- 4 Arquitectura
- 5 Entrenamiento
- 6 Inferencia y score
- 7 Calibración y evaluación
- 8 Adaptación, reproducibilidad y conclusiones

Planteamiento

En lugar de enseñar al modelo todas las patologías posibles, se aprende únicamente cómo son los cortes **normales**.

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N.$$

- Los pesos se entrenan solo con train/good (imágenes normales).
- Una anomalía es una imagen incompatible con la distribución normal aprendida.
- El sistema no identifica una enfermedad concreta, eso requeriría un enfoque supervisado.

¿Puede un **denoising autoencoder**, entrenado solo con cortes FLAIR **normales**, separar cortes normales de anómalos en BraTS2021_slice mediante el error de reconstrucción?

- **Entrenamiento del modelo:** aprendizaje de los pesos utilizando únicamente imágenes normales.
- **Selección del modelo:** elección de la mejor época mediante el conjunto de validación normal.
- **Calibración del umbral:** determinación del umbral de decisión utilizando imágenes normales y anómalas de validación.
- **Evaluación final:** evaluación sobre el conjunto de prueba, sin reajustar los pesos del modelo ni el umbral de decisión.

Partición	Normales	Anómalas	Uso
Entrenamiento	7.500	—	ajuste de pesos
Validación	39	44	mejor época y umbral
Test	640	3.075	evaluación final

- Cortes 2D FLAIR en PNG monocromo.
- Redimensionado de 240×240 a 128×128 para reducir coste computacional.
- Conversión a float32 y normalización a $[0, 1]$.
- Tensor final por imagen: $1 \times 128 \times 128$.
- Sin data augmentation geométrica.

El fondo de la resonancia es prácticamente negro y no aporta información útil para detectar anomalías cerebrales.

$$M = \mathbb{I}(x > 0,01)$$

- El umbral 0,01 separa fondo casi negro de primer plano.
- El ruido de entrenamiento se aplica solo donde $M = 1$.
- La MSE también se calcula solo sobre el primer plano.
- Así el modelo no obtiene una pérdida artificialmente baja por reconstruir fondo negro.

Un **autoencoder** es una red neuronal que aprende a reproducir su entrada sin necesitar una etiqueta de clase.

$$x \xrightarrow[\text{comprime}]{\text{encoder } g_\phi} z \xrightarrow[\text{reconstruye}]{\text{decoder } h_\psi} \hat{x}, \quad f_\theta = h_\psi \circ g_\phi.$$

Encoder

- Extrae características relevantes.
- Reduce progresivamente la resolución.
- Aumenta el contexto espacial de cada activación.

Decoder

- Recupera la resolución original.
- Convierte características en intensidades.
- Produce $\hat{x}$ con el mismo tamaño que x .

Un **denoising autoencoder (DAE)** es un AE entrenado para recuperar una imagen limpia x a partir de una versión corrompida $\tilde{x}$:

$$x \xrightarrow{q(\tilde{x}|x)} \tilde{x} \xrightarrow{f_\theta} \hat{x} \approx x.$$

- 1 Toma un corte cerebral normal y añade una corrupción artificial.
- 2 El encoder identifica estructura y contexto que sobreviven al ruido.
- 3 El decoder restaura una versión limpia plausible.
- 4 Para lograrlo, aprende patrones de los cortes normales, no una copia píxel a píxel.

Diferencia esencial

AE: $x \mapsto x$. DAE: $\tilde{x} \mapsto x$. La etiqueta objetivo sigue siendo la propia imagen, pero la entrada y el objetivo ya no son idénticos.

Autoencoder convencional

$$x \longrightarrow f_{\theta}(x) \approx x$$

- Puede aproximarse demasiado a la identidad.
- Una red potente podría reconstruir también anomalías.

Denoising Autoencoder

$$\tilde{x} \longrightarrow f_{\theta}(\tilde{x}) \approx x$$

- La entrada se corrompe artificialmente.
- El objetivo es recuperar la anatomía normal limpia.
- La tarea obliga a utilizar contexto espacial.

Basado en la idea de Kaschenas et al. [1].

Entrenamiento

$$\tilde{x} = x + n \longrightarrow \hat{x}, \quad \mathcal{L}(\hat{x}, x)$$

- Solo imágenes normales.
- Se añade ruido nuevo en cada pasada.
- Se actualizan los pesos para recuperar x .

Inferencia

$$x \longrightarrow \hat{x}, \quad A(x) = |x - \hat{x}|$$

- Se introduce la imagen limpia.
- No se actualizan pesos ni se añade ruido.
- El residuo se convierte en score de anomalía.

$$n_s \sim \mathcal{N}(0, I)_{16 \times 16}, \quad \tilde{x} = x + 0,2 M \odot \text{roll}(\text{up}(n_s))$$

- 1 Generar ruido gaussiano a baja resolución: 16×16 .
- 2 Interpolarlo bilinealmente a 128×128 .
- 3 Desplazarlo circularmente en posiciones aleatorias.
- 4 Aplicarlo solo al primer plano cerebral.

Por qué ruido grueso

Produce perturbaciones espaciales suaves y de mayor escala; eliminar ruido píxel a píxel sería una tarea más local y potencialmente más trivial.


La red reconstruye la imagen limpia:

$$\hat{x} = f_{\theta}(\tilde{x})$$

y optimiza una MSE de primer plano:

$$\mathcal{L}(\theta) = \frac{\sum M \odot (\hat{x} - x)^2}{\max(\sum M, 1)}.$$

- Es una regresión píxel a píxel.
- El cuadrado penaliza especialmente errores grandes.
- El fondo se excluye para centrar el aprendizaje en tejido cerebral.



- Cuatro niveles: 64, 128, 256 y 512 canales.
- Tres reducciones por AvgPool1d(2).
- Tres subidas bilineales + convolución.
- Skip connections entre escalas equivalentes.
- Salida final $1 \times 128 \times 128$ mediante convolución 1×1 .
- **8.558.721 parámetros entrenables.**

Cada ConvBlock aplica dos veces:

$$\text{Conv}_{3 \times 3} \rightarrow \text{SiLU} \rightarrow \text{GroupNorm}(8).$$

Elemento	Motivo
Conv. 3×3	Extraer patrones espaciales locales con pocos parámetros
padding=1	Mantener altura y anchura dentro de cada bloque
SiLU	Introducir una no linealidad suave
GroupNorm	Normalizar sin depender de estadísticas entre ejemplos del batch
Average pooling	Reducir resolución de forma suave
Skip connections	Recuperar detalle espacial para la reconstrucción
Salida lineal	Regresión de intensidad sin saturación de una sigmoide

Ejemplo en la primera etapa del decoder:

$$d_3 = \text{dec3}(\text{cat}(\text{up3}(e_4), e_3)) .$$

- e_4 : representación profunda a $16 \times 16 \times 512$.
- up3 : la convierte en $32 \times 32 \times 256$.
- e_3 : conserva detalle del encoder a $32 \times 32 \times 256$.
- La concatenación se hace en canales: $256 + 256 = 512$.
- dec3 transforma esos 512 canales en 256.

Idea

El decoder combina contexto profundo con información espacial de alta resolución.

- La **rama descendente** aumenta el campo receptivo: permite usar contexto anatómico y no solo comparar píxeles aislados.
- La **rama ascendente** devuelve la representación a la resolución necesaria para producir un mapa de error espacial.
- Las **skip connections** recuperan bordes y detalle que podrían perderse al reducir resolución.
- Los canales 64–128–256–512 aumentan la capacidad al disminuir el tamaño espacial, donde las activaciones son más baratas.

¿Las skips no facilitan copiar la anomalía?

Sí, es un riesgo real. Se conservan porque la reconstrucción médica necesita precisión espacial; el entrenamiento con corrupción gruesa obliga a combinar esas características locales con contexto. Es un compromiso, no una garantía.

Elección	Justificación
Dos conv. 3×3	Amplían el campo receptivo con menos parámetros que una convolución grande y permiten dos transformaciones no lineales
SiLU	Activación suave y derivable, con gradiente también para entradas negativas
GroupNorm (8 grupos)	No usa estadísticas del lote; es estable con batch 16 y divide exactamente todos los anchos de canal
Average pooling	Reduce resolución suavizando, en lugar de escoger solo el máximo local
Bilinear + conv.	Separa ampliación y aprendizaje y evita patrones de tablero asociados a algunas convoluciones transpuestas
Cabeza 1×1 lineal	Combina los 64 canales en una intensidad sin añadir contexto ni saturar la salida

Hiperparámetros

- Imagen: 128×128 .
- Batch: 16.
- Épocas: 50.
- Semilla: 42.
- Adam + AMSGrad.
- Learning rate: 10^{-4} .
- Weight decay: 10^{-5} .
- Ruido: $\sigma = 0,2$, resolución 16.

Control experimental

- Python, NumPy y PyTorch con semilla fija.
- cuDNN determinista.
- Mejor época por MSE en valid/good.
- Umbral fijado después con validación etiquetada.
- Test evaluado sin reajustes.

¿Por qué estos hiperparámetros?

Valor	Motivo práctico	Qué faltaría demostrar
Batch 16	Cabe en GPU y ofrece varias muestras por actualización	Compararlo con otros batches
50 épocas	Permite observar convergencia; se conserva la mejor, no necesariamente la última	Curva con más épocas
LR 10^{-4}	Paso conservador para Adam en una regresión densa	Barrido de tasas
Weight decay 10^{-5}	Penalización leve para limitar pesos excesivos	Ablación sin regularización
Base 64	Capacidad suficiente manteniendo coste manejable: 8,56 M de parámetros	Comparar anchuras
$\sigma = 0,2$	Corrupción visible sin destruir por completo la anatomía	Análisis de sensibilidad
Ruido 16^2	Al ampliarlo a 128^2 genera variaciones espaciales suaves	Comparar otras escalas

Valores inspirados en el método de referencia y fijados antes de mirar test.

Para cada lote:

`zero_grad` $\rightarrow$ `forward` $\rightarrow \mathcal{L}$ $\rightarrow$ `backward` $\rightarrow$ `optimizer.step`.

- **Adam**: adapta el tamaño de actualización usando momentos del gradiente.
- **AMSGrad**: variante de Adam que conserva un máximo histórico del segundo momento.
- **Weight decay**: regulariza los pesos.
- **CosineAnnealingLR**: $T_{\text{máx}} = 100$.

Detalle del código actual

`scheduler.step()` se ejecuta por lote, por lo que $T_{\text{máx}} = 100$ está expresado en **actualizaciones**, no en épocas. Esto produce ciclos rápidos de la tasa y debe revisarse mediante una ablación, no presentarse como una ventaja demostrada.

- **Adam** adapta el paso de cada parámetro usando medias móviles del gradiente y su cuadrado; ayuda cuando distintas capas tienen escalas de gradiente diferentes.
- **AMSGrad** conserva el máximo histórico del segundo momento; se adopta como variante conservadora de Adam.
- La **semilla 42** fija Python, NumPy, PyTorch y CUDA.
- **cuDNN determinista** y `benchmark=False` priorizan repetibilidad frente a velocidad máxima.

Límite de la semilla

Una ejecución reproducible no mide variabilidad. Para afirmar robustez hacen falta varias semillas y media $\pm$ desviación estándar.

Después de cada época se evalúan únicamente imágenes normales de validación.

$$e^* = \arg \min_e \text{MSE}_{\text{valid/good}}(e)$$

- Se entrenan las 50 épocas.
- Cuando mejora la MSE normal de validación se guarda una copia de los pesos.
- Al terminar, se recargan los pesos de la mejor época.
- Las imágenes anómalas no participan en esta selección.

En inferencia se introduce la imagen **limpia**; no se añade ruido.

$$e(x) = |x - f_{\theta}(x)|$$

Después:

- 1 Refinar la máscara con average pooling 5×5 y umbral 0,95.
- 2 Eliminar el error fuera del interior cerebral.
- 3 Aplicar mediana local 5×5 .

$$A(x) = f_{\text{med},5} \left(\tilde{M} \odot |x - f_{\theta}(x)| \right).$$

El filtro de mediana reduce respuestas puntuales aisladas.

BMAD proporciona una etiqueta por corte, por lo que el mapa debe reducirse a un único número:

$$s(x) = \max_{i,j} A(x)_{ij}.$$

- Una anomalía puede ocupar una región pequeña.
- Un promedio global podría diluirla entre miles de píxeles normales.
- El máximo pregunta si existe alguna región con error especialmente alto.
- La mediana previa evita que un único píxel ruidoso domine el score.

Operación	Función	Riesgo controlado
$ x - \hat{x} $	Mide magnitud del residuo sin cancelar signos	Una diferencia no implica por sí sola patología
Máscara erosionada	Exige que casi todo el vecindario 5×5 sea cerebro	Bordes cráneo-fondo producen errores altos
Mediana 5×5	Conserva respuestas locales consistentes y elimina impulsos	Un píxel espurio dominaría el máximo
Máximo espacial	Detecta una región pequeña sin diluirla	Puede favorecer un artefacto local persistente

Por qué no MSE como mapa de inferencia

El error absoluto mantiene el residuo en la escala de intensidad y crece linealmente; la MSE se reserva como objetivo de entrenamiento, donde interesa penalizar con fuerza reconstrucciones muy alejadas.

Con los scores y etiquetas de **validación** se calcula la curva ROC. El código selecciona:

$$t^* = \arg \max_t (TPR(t) - FPR(t)) .$$

Es el criterio de Youden:

$$J = \text{sensibilidad} + \text{especificidad} - 1.$$

Regla metodológica

El threshold se selecciona una sola vez en validación y después se aplica sin cambios al test.

- Youden maximiza $TPR - FPR$, equivalente a maximizar sensibilidad + especificidad $- 1$.
- Da el mismo peso a ambas clases y no depende de su proporción en el conjunto, algo importante con clases desbalanceadas.
- Produce una regla binaria única sin imponer aquí un coste clínico específico para FP o FN.
- Calibrar en test filtraría información del conjunto reservado y daría una estimación optimista del rendimiento.

Qué no significa

No es necesariamente el umbral clínico óptimo. Si el coste de un falso negativo fuese mayor, habría que elegir otro punto operativo y validarlo prospectivamente.

AUROC

Evalúa la capacidad del score para ordenar anómalas por encima de normales sin depender de un threshold concreto. 0,5 equivale al azar y 1 a separación perfecta.

Balanced accuracy

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Es adecuada porque el test contiene 640 normales y 3.075 anómalas.

AUROC: calidad del ranking

- Usa todos los umbrales posibles.
- No depende del threshold seleccionado.
- Mide si una anomalía tiende a recibir mayor score que una normal.

BA: decisión operativa

- Evalúa el threshold ya congelado.
- Promedia sensibilidad y especificidad.
- Evita que las 3.075 anomalías oculten el rendimiento en 640 normales.

Por qué no accuracy convencional

Predecir siempre la clase mayoritaria ya daría $3,075/3,715 = 82,8\%$ de accuracy, aunque la especificidad fuese cero.

Principios conservados

- DAE tipo U-Net.
- Tres reducciones y skips.
- Ruido gaussiano grueso.
- 16×16 y $\sigma = 0,2$.
- MSE de primer plano.
- Error absoluto y filtro mediana.

Adaptaciones del proyecto

- Un canal FLAIR.
- Cortes 2D independientes.
- Score escalar por imagen.
- Interpolación bilineal + convolución.
- GroupNorm con 8 grupos.
- AUROC y balanced accuracy.
- Threshold de Youden en validación.

La implementación separa responsabilidades:

- `data.py`: carga, particiones y preprocesado.
- `dae.py`: arquitectura U-Net del DAE.
- `experiment.py`: entrenamiento, score, threshold y métricas.
- `train.py`: interfaz de ejecución.
- Notebook Colab: GPU, descarga de datos, smoke test y entrenamiento completo.

Cada ejecución guarda pesos, configuración, historial, scores individuales, threshold, métricas y reconstrucciones.

Partición	AUROC	BA
Validación	0,9452	0,8820
Test	0,9633	0,9097


- 50 épocas; seed 42.
- Época seleccionada: 47.
- Threshold: 0,18611.
- Tiempo: 1,58 h en GPU.

Test: 3.715 cortes

Sensibilidad: 0,9210; especificidad: 0,8984.

TP: 2.832; TN: 575; FP: 65; FN: 243.

DAE: original (arriba) / reconstrucción (abajo)



Fila superior: entradas originales. Fila inferior: reconstrucciones generadas por el DAE. El score se calcula después a partir de su diferencia.

- AUROC 0,9633: el score ordena correctamente una pareja anómala–normal elegida al azar en aproximadamente el 96,3 % de los casos.
- Sensibilidad 0,9210: detecta 2.832 de 3.075 cortes anómalos.
- Especificidad 0,8984: identifica como normales 575 de 640 cortes normales.
- Balanced accuracy 0,9097: promedio de las dos tasas anteriores.
- La mejora de AUROC de validación (0,9452) a test (0,9633) puede ser variación muestral; no demuestra que el modelo mejore al ver test.

Conclusión proporcionada

Los resultados apoyan la separabilidad en este benchmark y esta ejecución; no prueban diagnóstico, localización exacta ni generalización clínica.

Pregunta	Respuesta breve
¿Es realmente no supervisado?	Los pesos se aprenden solo con normales y sin etiquetas; el threshold sí usa etiquetas de validación: es calibración supervisada
¿Por qué no entrenar un clasificador?	Requeriría anomalías etiquetadas y aprendería las patologías presentes; aquí se evalúa modelado de normalidad
¿El error reconstruye el tumor o lo localiza?	Es una señal de discrepancia; con etiquetas por corte solo validamos clasificación, no segmentación
¿Por qué no afirmar uso clínico?	Falta validación externa, análisis por paciente, múltiples semillas y estudio de errores clínicos
¿Es definitivo el threshold 0,18611?	No: depende de validación, preprocesado y coste de errores; no debe transferirse sin recalibrar

- Una modalidad FLAIR 2D pierde información multimodal y tridimensional.
- Una etiqueta por corte no permite evaluar localización de lesión.
- El máximo espacial puede ser sensible a artefactos locales.
- La validación es pequeña: 39 normales y 44 anómalas.
- El threshold usa etiquetas de validación: los pesos son no supervisados, pero la decisión binaria final está calibrada supervisadamente.
- Un benchmark no demuestra generalización clínica externa.

- Se implementó un DAE tipo U-Net entrenado **solo con normales**.
- El ruido grueso convierte el aprendizaje en una tarea de restauración, no en una simple copia de la entrada.
- El error de reconstrucción se filtra y reduce a un score por corte.
- Pesos, calibración y test están metodológicamente separados.
- En test: AUROC 0,9633 y balanced accuracy 0,9097.

Trabajo futuro: varias semillas, ablaciones de hiperparámetros, información multimodal/3D, máscaras de lesión y validación externa.

¡Gracias!

Alejandro Rodríguez

Detección no supervisada de anomalías mediante un DAE



Antanas Kascenas, Nicolas Pugeault, and Alison Q. O’Neil.

Denoising autoencoders for unsupervised anomaly detection in brain MRI.

In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 653–664, 2022.