

Alejandro Rodríguez

Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos
Universitat de les Illes Balears

Curso 2025/26



Universitat
de les Illes Balears

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

- 1 Motivación y objetivo
- 2 Fundamento del DAE
- 3 Datos y arquitectura
- 4 Score y adaptación del paper
- 5 Entrenamiento y evaluación
- 6 Resultados provisionales
- 7 Reproducibilidad y conclusiones

Limitación del aprendizaje supervisado en imagen médica

- Necesita ejemplos anotados de cada alteración posible.
- La anotación radiológica requiere tiempo experto y presenta variabilidad.
- Una clase patológica no observada durante el entrenamiento puede quedar fuera.

Aprender solo la **normalidad** y puntuar cuánto se aparta cada imagen:

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N.$$

¿Puede un **denoising autoencoder**, entrenado solo con cortes FLAIR **normales**, separar de forma útil y reproducible los cortes normales de los anómalos en BraTS2021_slice?

- “Anómalo” significa no normal según BMAD; no confirma una patología.
- Objetivo: línea base sencilla, explicable y reproducible.
- Protocolo: pesos con train normal, umbral en validación, una evaluación en test.

Autoencoder convencional

- Aprende $x \rightarrow \hat{x}$.
- Un cuello de botella fuerte puede degradar tejido normal.
- Demasiada capacidad puede copiar también la anomalía.

DAE de Kascenas et al. [1]

- Aprende $\tilde{x} \rightarrow x$.
- U-Net con conexiones de salto.
- Sin vector latente restrictivo.
- El ruido espacial obliga a aprender anatomía normal.

Idea central

Una lesión hiperintensa no vista puede parecer una corrupción: el DAE tiende a retirarla o reconstruirla mal, dejando un residuo elevado.

$$n_s \sim \mathcal{N}(0, I)_{16 \times 16}, \quad \tilde{x} = x + 0,2 M \odot \text{roll}(\text{up}(n_s))$$

- ❶ Muestrear ruido gaussiano a 16×16 .
- ❷ Interpolarlo bilinealmente a 128×128 .
- ❸ Trasladarlo aleatoriamente para variar los centros de los patrones.
- ❹ Aplicarlo solo al cerebro: $M = \mathbb{1}(x > 0,01)$.


Objetivo

$$\mathcal{L} = \frac{\sum M \odot (f_{\theta}(\tilde{x}) - x)^2}{\max(\sum M, 1)}$$

MSE únicamente sobre el primer plano; el fondo no domina el aprendizaje.

Partición	Normales	Anómalas	Uso
Entrenamiento	7.500	—	ajuste de pesos
Validación	39	44	mejor época y umbral
Test	640	3.075	evaluación final

- Cortes 2D FLAIR, PNG monocromos; etiqueta por imagen.
- Conversión a escala de grises y rango $[0, 1]$.
- Redimensionado de 240×240 a 128×128 .
- **Sin** data augmentation geométrica.



- Cada bloque: $[\text{Conv}_{3 \times 3} \rightarrow \text{SiLU} \rightarrow \text{GroupNorm}] \times 2$.
- Average pooling; subida bilineal seguida de convolución; head 1×1 .
- 3 reducciones, sin bottleneck vectorial, **8.558.721 parámetros**.

Decisión	Función
Convolución 3×3	Extraer contexto local conservando resolución
SiLU/Swish	Activación suave utilizada en el método de referencia
GroupNorm	Estabilidad sin depender de lotes grandes
Average pooling	Reducir resolución preservando intensidades suaves
Skip connections	Recuperar bordes y detalle anatómico normal
Salida lineal	Regresión de intensidad sin saturación de una sigmoide

En test se introduce la imagen **limpia**; no se añade ruido.

$$A(x) = f_{\text{med},5} \left(\tilde{M} \odot |x - f_{\theta}(x)| \right), \quad s(x) = \max_{i,j} A(x)_{ij}.$$

- ❶ Erosionar la máscara para ignorar errores del borde del cráneo.
- ❷ Calcular error absoluto por píxel.
- ❸ Aplicar mediana 5×5 para eliminar respuestas aisladas.
- ❹ Tomar el máximo espacial: una puntuación por corte.

Diferencia clave

El paper conserva $A(x)$ para segmentar; BMAD exige reducirlo a $s(x)$ para clasificar toda la imagen.

Conservado del paper

- U-Net, 3 reducciones y skips.
- Canales 64–128–256–512.
- SiLU, GroupNorm y average pooling.
- Ruido 16×16 , $\sigma = 0,2$ y roll.
- MSE de primer plano.
- Residuo absoluto + mediana 5×5 .

Adaptado al proyecto

- 1 FLAIR en lugar de 4 modalidades.
- Clasificación por corte, no segmentación.
- Convolución estándar, sin weight standardization.
- Bilinear + conv en lugar de transposed conv.
- 8 grupos fijos y padding cero.
- Normalización del PNG a $[0, 1]$.

	Paper	Este proyecto
Dato	4 modalidades + máscara	FLAIR + etiqueta de corte
Salida evaluada	mapa por píxel	score escalar
Métricas	AUPRC y Dice	AUROC y balanced accuracy
Umbral	Dice óptimo analítico	Youden en validación
Postproceso	mediana y CC 3D	mediana 2D

Razón metodológica: no inventar máscaras ni estructura 3D ausentes y no utilizar test para calibrar la decisión.

Entrenamiento

- Batch: 16.
- Adam + AMSGrad.
- $lr_{\text{máx}} = 10^{-4}$.
- Weight decay: 10^{-5} .
- Ciclo coseno: 200 updates.
- 143 épocas ≈ 67.067 updates.

Control experimental

- Semillas: 13, 42 y 73.
- cuDNN determinista.
- Mejor época por MSE normal de validación.
- Umbral fijado con validación etiquetada.
- Test evaluado sin reajustes.

AUROC

Probabilidad de que una imagen anómala elegida al azar reciba mayor score que una normal. No depende del umbral; 0,5 equivale al azar.

Balanced accuracy

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Da el mismo peso a normales y anómalas pese al desbalance de test.

Se reportará **media** $\pm$ **desviación típica** de las tres semillas.


No son resultados experimentales

Estos números son marcadores provisionales. Se sustituirán por los tres `metrics.json` de Colab antes de interpretar o entregar el trabajo.

Semilla	AUROC test	Balanced accuracy test
13	0,876	0,798
42	0,899	0,827
73	0,886	0,811
Media $\pm$ d.t.	0,887 $\pm$ 0,011	0,812 $\pm$ 0,014

No citar ni comparar estos valores.

DAE: original (arriba) / reconstrucción (abajo)



Arriba: imágenes normales. Abajo: reconstrucciones del DAE. Esta ejecución utilizó 128 imágenes y 5 épocas: valida el flujo, no el rendimiento.

- Configuración, historial completo y época seleccionada en `metrics.json`.
- Pesos y arquitectura en `model.pt`.
- Scores individuales de validación y test en CSV.
- Reconstrucciones visuales de control.
- Notebook de Colab con comprobación de GPU, smoke test y campaña completa.
- Ejecución final de tres semillas y resumen agregado en `results/resultados.csv`.

- Una modalidad 2D pierde información multimodal y tridimensional.
- La etiqueta por corte no permite evaluar localización tumoral.
- El máximo espacial puede reaccionar a artefactos locales.
- La validación es pequeña: 39 normales y 44 anómalas.
- Un benchmark no demuestra generalización a otros centros o escáneres.
- Software experimental; no apto para diagnóstico ni decisiones clínicas.

- Se implementó una adaptación unimodal y por corte del DAE de Kascenas et al., entrenada **solo con normales**.
- La red conserva el núcleo del método: U-Net sin bottleneck restrictivo, ruido grueso y error de reconstrucción filtrado.
- Entrenamiento, selección de época, calibración y test están separados.
- La campaña de tres semillas permitirá cuantificar rendimiento y variabilidad.
- Las conclusiones cuantitativas quedan pendientes de los resultados de Colab.

Trabajo futuro: recuperar cuatro modalidades y máscaras, evaluar por paciente y validar externamente.

¡Gracias!

Alejandro Rodríguez

Detección no supervisada de anomalías mediante un DAE



Antanas Kascenas, Nicolas Pugeault, and Alison Q. O'Neil.

Denoising autoencoders for unsupervised anomaly detection in brain MRI.

In *Proceedings of the 5th Conference on Medical Imaging with Deep Learning*, volume 172 of *Proceedings of Machine Learning Research*, pages 653–664, 2022.