



Alejandro Rodríguez

Máster Universitario en Sistemas Inteligentes (MUSI)
Especialidad en Inteligencia Artificial y Ciencia de Datos
Universitat de les Illes Balears

Curso 2025/26



Universitat
de les Illes Balears

Tutor(es): Gabriel Moyà Alcover y Miquel Miró Nicolau

- 1 Motivación y objetivos
- 2 Fundamentos y estado del arte
- 3 Metodología
- 4 Puntuación y calibración
- 5 Resultados
- 6 Reproducibilidad
- 7 Conclusiones y trabajo futuro

El problema del aprendizaje supervisado en imagen médica

- Requiere ejemplos **etiquetados** de cada categoría.
- Anotar en radiología exige **tiempo experto** y tiene **variabilidad entre observadores**.
- No es viable enumerar *todas* las posibles alteraciones.

Enfoque alternativo: aprender la **apariencia normal** y señalar lo que se aparta de ella $\Rightarrow$ **detección de anomalías** no supervisada.

¿Puede un **autoencoder sencillo**, entrenado solo con cortes cerebrales **normales**, separar de forma útil y reproducible las imágenes normales de las no normales en BraTS2021?

- **"Anómala"** $\equiv$ *no normal* según la anotación de BMAD, no confirma una patología concreta.
- El objetivo es **explicabilidad** y **reproducibilidad**, no un diagnóstico clínico.

¿Puede un **autoencoder sencillo**, entrenado solo con cortes cerebrales **normales**, separar de forma útil y reproducible las imágenes normales de las no normales en BraTS2021?

- **.Anómala"** $\equiv$ *no normal* según la anotación de BMAD, no confirma una patología concreta.
- El objetivo es **explicabilidad** y **reproducibilidad**, no un diagnóstico clínico.

General: diseñar, implementar y evaluar un sistema no supervisado, sencillo y reproducible basado en reconstrucción con autoencoder.

Específicos:

- 1 Revisar la detección de anomalías por reconstrucción y justificar sus supuestos mediante bibliografía.
- 2 Obtener y **auditar** BraTS2021 (conteos, formato, legibilidad).
- 3 Implementar un AE convolucional con preprocesado y **data augmentation**.
- 4 **Evitar fuga de información:** entrenar solo con normales, calibrar en validación, evaluar en test.
- 5 Lograr una **separación útil** con solución explicable.
- 6 Entregar experimento **reproducible** con demos visuales.

El autoencoder minimiza el error de reconstrucción $\mathcal{L}_{AE} = \|x - g_{\theta}(f_{\phi}(x))\|_1$.

Variantes en la literatura

- AE variacional: regulariza el espacio latente [5].
- Modelos generativos adversariales [4].
- Variantes adaptadas a imagen médica [8, 3].

Protocolos

- Benchmarks: MVTec AD [2] y BMAD [1].
- Revisión de anomalías [6].
- Unified framework [7].

Decisión

Se busca la **mínima solución defendible** para la pregunta planteada, evitando sobreestimación por exceso de capacidad.


Cortes cerebrales FLAIR, PNG monocromos de **240×240** (resolución nativa).

Partición	Normales	Anómalas	Uso
Entrenamiento	7.500	—	solo normales (pesos)
Validación	39	44	calibración y umbral
Test	640	3.075	evaluación final

Preprocesado: conversión a escala de grises (los PNG originales son RGBA) y escala de intensidades a $[0, 1]$.

Data augmentation: flip horizontal (50 %), flip vertical (50 %) y rotación 90/180/270°.

ConvAutoencoder (16,281 parámetros)



Como el modelo solo ha visto **normales**:

- Normal $\Rightarrow$ reconstruye bien $\Rightarrow$ **error pequeño**.
- Anómalo $\Rightarrow$ reconstruye mal $\Rightarrow$ **error grande**.

Puntuación híbrida (modo hybrid)

$$s(x) = w \cdot z(\text{global}) + (1 - w) \cdot z(\text{MAE})$$

donde $z(\cdot)$ es la señal **calibrada** (tipificada) y w el peso elegido en validación.

Estadísticos **globales** de la imagen original: se calculan *antes y aparte* del autoencoder, en una sola pasada sobre los píxeles.

- 1 Se calculan **5 estadísticos**; se seleccionan **4 señales** interpretables (GLOBAL_SIGNALS).
- 2 Cada señal se **tipifica** contra su distribución en las normales de entrenamiento y se suma:

$$z_k(x) = \frac{\text{signo}_k \cdot x_k - \mu_k}{\sigma_k}, \quad z(\text{global}) = \sum_k z_k(x)$$

- 3 El **signo** se fija por la dirección del AUROC en validación.
- 4 Se combina con el MAE: $s(x) = w z(\text{global}) + (1 - w) z(\text{MAE})$.

Las 4 señales (una diapositiva por señal)

1. Kurtosis 2. Región brillante más grande (cc_largest) 3. Gradiente medio (grad_mean) 4. Entropía

Estadísticos **globales** de la imagen original: se calculan *antes y aparte* del autoencoder, en una sola pasada sobre los píxeles.

- 1 Se calculan **5 estadísticos**; se seleccionan **4 señales** interpretables (GLOBAL_SIGNALS).
- 2 Cada señal se **tipifica** contra su distribución en las normales de entrenamiento y se suma:

$$z_k(x) = \frac{\text{signo}_k \cdot x_k - \mu_k}{\sigma_k}, \quad z(\text{global}) = \sum_k z_k(x)$$

- 3 El **signo** se fija por la dirección del AUROC en validación.
- 4 Se combina con el MAE: $s(x) = w z(\text{global}) + (1 - w) z(\text{MAE})$.

Las 4 señales (una diapositiva por señal)

1. Kurtosis 2. Región brillante más grande (cc_largest) 3. Gradiente medio (grad_mean) 4. Entropía

Qué es: momento (estandarizado) de 4.º orden de la distribución de intensidades; describe si el histograma es **puntiagudo o aplastado**.

$$\text{kurt}(x) = \frac{\mathbb{E}[(x - \mu)^4]}{\sigma^4}$$

- **Analogía:** “¿cuánta masa hay en el centro y cuánta en las colas?” de la distribución de grises.
- **En FLAIR:** una lesión hiperintensa añade un *pico extra* de brillo separado del tejido $\Rightarrow$ la distribución se vuelve puntiaguda $\Rightarrow$ **kurtosis más alta**.

Comportamiento validado

Signo +1: a mayor kurtosis, mayor puntuación de anomalía.

Qué es: el tamaño, en fracción del área, de la **componente conexas de píxeles brillantes más grande**.

- Umbral de brillo: $x > \max(p_{90}(x), 0,9)$, conectividad de 4 vecinos.
- **Analogía:** la “isla de luz” más grande de la imagen.
- **En FLAIR:** el tejido normal tiene regiones brillantes pequeñas y dispersas; el **edema/tumor forma una mancha grande y contigua** $\Rightarrow$ cc_largest alto.

Comportamiento validado

Signo +1: a mayor mancha brillante contigua, mayor puntuación.

Qué es: promedio de la magnitud del gradiente de intensidad; mide la **cantidad de borde/textura** de la imagen.

$$\text{grad}(x) = \sqrt{g_x^2 + g_y^2}, \quad g_x = \frac{\partial x}{\partial i}, \quad g_y = \frac{\partial x}{\partial j}$$

- **Analogía:** “¿cuánto cambia el brillo entre píxeles vecinos?” Muy baja en zonas planas, alta en los bordes.
- **En FLAIR:** en este dataset las anómalas presentan **menos gradiente** medio: la lesión difusa *emborrona* los márgenes del tejido.

Comportamiento validado

Signo -1 (fijado automáticamente en validación): menos gradiente $\Rightarrow$ más puntuación.

Qué es: entropía de Shannon del histograma de intensidades (32 intervalos); mide el **desorden / variedad de niveles de gris**.

$$H(x) = - \sum_{b=1}^{32} p_b \ln p_b$$

- **Analogía:** cuánta “sorpresa” hay en la imagen: plana $\Rightarrow$ poco desorden; con muchos niveles de gris $\Rightarrow$ mucho desorden.
- **En FLAIR:** la lesión introduce una **segunda distribución** de intensidades $\Rightarrow$ más variedad $\Rightarrow$ **entropía mayor**.

Comportamiento validado

Signo +1: a mayor desorden de intensidades, mayor puntuación.

- El MAE y las señales globales están en escalas distintas $\Rightarrow$ **tipificación** (z-score).
- Se busca el peso w que **maximiza el AUROC en validación**, probando una rejilla de 21 valores entre 0 y 1.
- La validación **nunca actualiza pesos**: solo interviene en la calibración y en el umbral.

Resultado en validación (semilla 42)

AUROC global sola: 0,883 AUROC MAE solo: 0,687 **Híbrido**: 0,886 $\Rightarrow w = 0,95$

Métricas

AUROC (independiente del umbral) + **balanced accuracy** (media de sensitivity y specificity, justa con clases desbalanceadas).


Métrica	Valor	Interpretación
AUROC	0,9029	Probabilidad de puntuar más alto una anómala que una normal
Balanced accuracy	0,8332	media de sensitivity y specificity
Sensitivity	0,7554	Proporción de anomalías correctamente detectadas
Specificity	0,9109	Proporción de normales correctamente identificadas
Peso híbrido (w)	0,95	95 % global + 5 % MAE
Umbral de decisión	1,943	fijado en validación, congelado para test
Parámetros	16.281	modelo ligero

Lectura clave: las señales globales ($w = 0,95$) aportan más información discriminativa que el error de reconstrucción.

Métrica	Valor	Interpretación
AUROC	0,9029	Probabilidad de puntuar más alto una anómala que una normal
Balanced accuracy	0,8332	media de sensitivity y specificity
Sensitivity	0,7554	Proporción de anomalías correctamente detectadas
Specificity	0,9109	Proporción de normales correctamente identificadas
Peso híbrido (w)	0,95	95 % global + 5 % MAE
Umbral de decisión	1,943	fijado en validación, congelado para test
Parámetros	16.281	modelo ligero

Lectura clave: las señales globales ($w = 0,95$) aportan más información discriminativa que el error de reconstrucción.


AI: original (ambal) / reconstrucció (bajal)




El modelo reconstruye fielmente la anatomía normal $\Rightarrow$ el residuo es bajo en normales.

Detección de anomalías en corte cerebral - TFM - Normal (01221_99.png)


1. Imagen original




2. Reconstrucción AE




3. Mapa de error




4. Regiones anómalas



5. Señales globales de la imagen




6. Score: -2.449 -> NORMAL




Deteccion de anomalias en corte cerebral - TFM - Anomalo (00006_60.png)


1. Imagen original




2. Reconstruccion AE



3. Mapa de error



4. Regiones anomalas



5. Senales globales de la imagen



6. Score: 13.506 -> ANOMALA



- Semillas fijas, configuración, historial, puntuaciones y métricas guardados.
- Campaña final: **semilla 42, 10 épocas**, data augmentation, 240×240 , score híbrido.
- Entregables: `metrics.json`, `model.pt`, `*_scores.csv`, `reconstructions.png`, checkpoint `checkpoints/modelo_autoencoder.pt`.
- Entrenamiento reproducible en **Google Colab con GPU** (notebook + smoke test + campaña completa).

- Se obtuvo y auditó BraTS2021; se implementó el AE con augmentation entrenado **solo con normales**.
- Sistema **explicable**: 3 etapas, 16.281 parámetros, fórmula híbrida explícita.
- **AUROC 0,9029** y **balanced accuracy 0,8332**.
- El **score híbrido** ($w = 0,95$) muestra que las señales globales complementan (y superan) al error de reconstrucción.
- Se aporta código, pesos y demostración reproducibles.

Trabajo futuro

- Validar en otro centro / dataset.
- Explorar U-Net con conexiones de salto.
- Analizar por subgrupos qué anomalías se detectan mejor.

Limitaciones

- Software **experimental**, no apto para diagnóstico.
- “Anómalo” $\neq$ confirmación de patología.
- No sustituye la interpretación de un profesional.

¡Gracias!

Alejandro Rodríguez

Detección no supervisada de anomalías en cortes cerebrales

Máster Universitario en Sistemas Inteligentes (MUSI) — UIB



Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang, and Xingyu Li.

BMAD: Benchmarks for medical anomaly detection.

In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pages 4042–4053, 2024.



Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger.

MVTec AD: A comprehensive real-world dataset for unsupervised anomaly detection.

In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019.



Mariana-Iuliana Georgescu.

Masked autoencoders for unsupervised anomaly detection in medical images.

In *Procedia Computer Science: KES 2023*, 2023.



Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio.

Generative adversarial nets.

In *Advances in Neural Information Processing Systems*, volume 27, pages 2672–2680, 2014.



Diederik P. Kingma and Max Welling.

Auto-encoding variational bayes.

In *International Conference on Learning Representations*, 2014.



Guansong Pang, Chunhua Shen, Longbing Cao, and Anton van den Hengel.

Deep learning for anomaly detection: A review.

ACM Computing Surveys, 54(2):1–38, 2021.



Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, and Klaus-Robert Müller.

A unifying review of deep and shallow anomaly detection.
Proceedings of the IEEE, 109(5):756–795, 2021.



Haibo Zhang, Wenping Guo, Shiqing Zhang, Hongsheng Lu, and Xiaoming Zhao.

Unsupervised deep anomaly detection for medical images using an improved adversarial autoencoder.
Journal of Digital Imaging, 35(2):153–161, 2022.