

Detección no supervisada de anomalías en radiografías de tórax

Un autoencoder sencillo, reproducible y explicable

Alejandro Rodríguez

Máster Universitario en Sistemas Inteligentes
Universitat de les Illes Balears

Julio de 2026

Problema y pregunta

Problema

No es viable disponer de ejemplos etiquetados de todas las posibles alteraciones radiológicas.

Pregunta: ¿puede un modelo entrenado solo con radiografías normales separar las normales de las no normales?

- Salida: puntuación de anomalía, no diagnóstico.
- Prioridad: arquitectura pequeña y fácil de defender.

Objetivos

- ➊ Obtener y auditar un dataset público adecuado.
- ➋ Implementar las tres familias de la propuesta: AE, VAE y GANomaly.
- ➌ Entrenar pesos exclusivamente con imágenes normales.
- ➍ Separar entrenamiento, calibración y prueba.
- ➎ Conseguir una separación útil y estable con una solución mínima.
- ➏ Entregar código, un checkpoint y una demostración.


Dataset y protocolo

Chest-RSNA (BMAD): 26.684 radiografías, resolución original 1024 por 1024 píxeles.

Partición	Normales	Anómalas
Entrenamiento	8.000	0
Validación	70	1.420
Test	781	16.413

- Un canal, 64 por 64 píxeles, intensidades normalizadas.
- Pesos: solo entrenamiento normal.
- Signos y umbral: validación. Resultado final: test congelado.

Arquitectura del autoencoder final



Tres convoluciones comprimen la imagen y tres convoluciones transpuestas recuperan su resolución.

Una puntuación transparente

El MAE aislado tenía dirección inversa en este dataset. No añadimos otro modelo: calibramos dos señales sencillas en validación.

$$s(x) = 0,5 z(\text{MAE}(x)) + 0,5 z(\text{intensidad}_{\text{centro}} - \text{intensidad}_{\text{borde}})$$

- Pesos fijos 50/50: no hay búsqueda de hiperparámetros.
- Validación decide el signo y el umbral.
- Ninguna anomalía actualiza los pesos del autoencoder.

Resultados en tres semillas

Método	Parámetros	AUROC	Bal. acc.
VAE	740.993	0,4506	0,5064
GANomaly	959.586	0,5636	0,5484
Control gradiente	0	0,5981	0,5894
AE final	16.281	0,7608	0,6790

Semillas AE: 0,7608; 0,7603; 0,7614. La reducida dispersión muestra que el resultado es estable.

¿Por qué mejora?

- El AE pequeño tiene menos capacidad para copiar cualquier entrada.
- La calibración no presupone que una anomalía siempre tenga más error.
- Centro–borde aporta una señal global complementaria y explicable.
- La combinación supera cada señal por separado sin añadir otra red.
- Tiene unas 59 veces menos parámetros que GANomaly.

Lección

Una puntuación adecuada puede importar más que aumentar la arquitectura.

Demostración y reproducibilidad

Entrenamiento completo

```
python run.py
```

Una radiografía

```
python demo.py ruta/a/imagen.png
```

La demo carga `modelo_autoencoder.pt`, reconstruye la imagen, calcula la puntuación y la compara con el umbral congelado. Se entregan configuración, resultados CSV, tres semillas y un solo checkpoint final.

Limitaciones

- “Anómala” significa no normal según RSNA/BMAD; no diagnostica una patología concreta.
- El test está muy desequilibrado: 95,46 % de anomalías.
- 64×64 puede eliminar hallazgos pequeños.
- Centro–borde puede capturar adquisición o encuadre, no solo anatomía.
- El test fue consultado durante el desarrollo: falta validación externa sin reajuste para estimar generalización clínica.

Conclusiones

- La propuesta se cumple: AE, VAE y GANomaly, entrenados con normales.
- El sistema final obtiene AUROC 0,7608.
- La solución ganadora es también la menor: seis capas y 16.281 parámetros.
- Es estable, reproducible y se explica con una fórmula.
- Es un prototipo de investigación, no una herramienta clínica.

Gracias. ¿Preguntas?