

Universitat de les Illes Balears

Máster Universitario en Sistemas Inteligentes

Trabajo Fin de Máster

Detección de anomalías en radiografías de tórax mediante autoencoders

Comparación de AE, VAE y GANomaly con una referencia supervisada

Autor: Alejandro Rodríguez
Tutores: Gabriel Moyà Alcover
Miquel Miró Nicolau

Curso 2025–2026
Palma, julio de 2026

Resumen

La escasez de anotaciones clínicas exhaustivas limita el entrenamiento de detectores supervisados capaces de reconocer patologías diversas. Este trabajo estudia si un modelo entrenado exclusivamente con radiografías normales puede asignar una puntuación alta a imágenes no normales. Se comparan, bajo un mismo protocolo, un autoencoder convolucional (AE), un autoencoder variacional (VAE) y GANomaly, una arquitectura adversarial. Se emplea Chest-RSNA, la partición de radiografías del benchmark BMAD: 8.000 imágenes normales para entrenamiento, 1.490 para validación y 17.194 para prueba. En tres semillas, GANomaly obtiene AUROC $0,5636 \pm 0,0150$, por encima de AE ($0,4566 \pm 0,0163$) y VAE ($0,4506 \pm 0,0016$). Un control de gradiente alcanza 0,5981. Como referencia práctica se añade un único clasificador convolucional supervisado, que logra $0,8538 \pm 0,0070$ sin consultar el test durante el desarrollo. El contraste muestra que las etiquetas aportan una señal que los métodos de reconstrucción no captan. La contribución es una comparación reproducible, no un diagnóstico.

1. Contextualización y motivación

1.1. Problema

La imagen médica es una fuente central de información diagnóstica, pero un algoritmo convencional necesita ejemplos representativos y correctamente etiquetados de cada entidad que deberá reconocer. En radiología, obtener esas etiquetas exige tiempo experto, los hallazgos pueden ser sutiles, existe variabilidad entre observadores y la distribución de patologías es muy desigual. Además, un clasificador cerrado aprende las categorías disponibles y puede responder con excesiva confianza ante un patrón no representado. Estas condiciones motivan la detección de anomalías: modelar la normalidad y señalar desviaciones sin exigir ejemplos de todas las enfermedades posibles [1, 2].

La formulación de una clase es especialmente natural cuando abundan muestras sanas y las anomalías son heterogéneas. Sea x una radiografía y f_θ un modelo ajustado con el conjunto normal $\mathcal{D}_N$. Se busca una función $s(x)$ tal que

$$s(x_N) < s(x_A), \quad x_N \sim p_N, \quad x_A \not\sim p_N,$$

sin utilizar x_A para optimizar θ . El resultado no es un diagnóstico, sino una puntuación de incompatibilidad con la distribución aprendida.

1.2. Por qué reconstrucción generativa

Un autoencoder comprime la entrada en una representación latente y aprende a reconstruirla [3]. Si solo observa imágenes normales, se espera que reconstruya peor una alteración y que el residuo sirva como señal de anomalía. La hipótesis es atractiva, pero no está garantizada: una red con mucha capacidad puede copiar también una entrada anómala; el error puede estar dominado por contraste, bordes o adquisición, y una reconstrucción visualmente nítida no implica mejor discriminación [4].

El VAE introduce una representación probabilística regularizada mediante la divergencia de Kullback–Leibler [5]. Esto puede producir un espacio latente más continuo, aunque también reconstrucciones suavizadas. Las GAN enfrentan generador y discriminador [6]; aplicaciones como AnoGAN y GANomaly trasladan ese aprendizaje adversarial a detección de anomalías [7, 8]. La literatura médica incluye autoencoders adversariales, VAE en cascada y autoencoders enmascarados [9, 10, 11]. No obstante, las diferencias de datasets, preprocesado y métricas dificultan saber qué parte de la mejora procede realmente del modelo.

1.3. Pregunta de investigación y alcance

La pregunta principal es: *¿qué familia, AE, VAE o GANomaly, separa mejor radiografías normales y no normales cuando todas se entrenan solo con normales y se evalúan bajo idénticas condiciones?*

El estudio usa radiografías frontales del benchmark Chest-RSNA de BMAD [12, 13]. “Anómala” significa *no normal según la taxonomía RSNA/BMAD*; no significa cualquier patología torácica ni confirma neumonía. La salida podría servir como señal de priorización o control de calidad en investigación, pero el sistema no está calibrado prospectivamente, no ha sido validado externamente y no debe utilizarse para decisiones clínicas.

1.4. Aportaciones

Las aportaciones concretas son: (i) selección y auditoría reproducible de un conjunto público adecuado; (ii) implementaciones comparables de AE, VAE y GANomaly; (iii) separación estricta entre ajuste, selección de umbral y prueba; (iv) evaluación con métricas robustas al desequilibrio y análisis de coste; y (v) una referencia supervisada mínima que cuantifica el valor de disponer de etiquetas; y (vi) publicación del código y de la configuración, sin redistribuir imágenes médicas.

2. Objetivos

2.1. Objetivo general

Diseñar, implementar y evaluar un sistema reproducible de detección no supervisada de anomalías en radiografías de tórax, comparando un AE, un VAE y una alternativa adversarial GAN bajo un protocolo común.

2.2. Objetivos específicos y criterios de logro

1. **Revisar el estado del arte** de detección de anomalías basada en reconstrucción, identificando supuestos, funciones de pérdida, puntuaciones y riesgos. Se considera cumplido al justificar las tres familias y el protocolo a partir de bibliografía primaria.
2. **Obtener y preparar un dataset médico adecuado.** Debe contener radiografías normales y anómalas, entrenamiento normal, validación y prueba. Se verifica mediante conteos, lectura de imágenes, dimensiones y control de duplicados exactos entre particiones.
3. **Implementar tres modelos comparables:** AE convolucional, VAE y GANomaly. Deben compartir resolución, dimensión latente, optimizador, presupuesto de épocas y semillas, y producir una puntuación por imagen.
4. **Definir una evaluación sin fuga de información.** Los pesos se ajustan solo con entrenamiento normal; el checkpoint se selecciona con validación normal; las etiquetas completas de validación fijan el umbral; el test se consulta una vez con el método congelado.
5. **Comparar efectividad y coste.** La métrica principal es AUROC de test; se reportan AUPRC, exactitud balanceada, sensibilidad, especificidad, F1, número de parámetros y tiempo. La afirmación de superioridad requiere la media de tres semillas y dispersión, no una ejecución aislada.
6. **Analizar limitaciones y reproducibilidad.** Se documentan desequilibrio, sesgos de adquisición, pérdida por redimensionado, significado limitado de la etiqueta y ausencia de validación clínica externa.
7. **Establecer una referencia supervisada simple.** Un único clasificador debe reutilizar el codificador existente, mantener el test intacto y mostrar si las etiquetas permiten una separación más útil.

Quedan fuera del alcance mínimo la localización de lesiones, la clasificación por patología, el uso asistencial y la comparación exhaustiva con métodos preentrenados modernos. Son extensiones válidas, pero diluirían la pregunta central y el presupuesto de un TFM individual de 18 ECTS.

3. Fundamentos y estado del arte

AE. Minimiza el error de reconstrucción $\mathcal{L}_{AE} = \|x - g_\theta(f_\phi(x))\|_1$. Su ventaja es la simplicidad; su debilidad es que el cuello de botella no impone una distribución latente y puede generalizar la reconstrucción fuera de la normalidad.

VAE. Aproxima $q_\phi(z | x)$ mediante una normal parametrizada y optimiza

$$\mathcal{L}_{VAE} = \|x - \hat{x}\|_1 + \beta D_{KL}(q_\phi(z | x) \| \mathcal{N}(0, I)) .$$

El truco de reparametrización permite derivar a través del muestreo [5]. Estudios recientes comparan variantes convolucionales y transformers y confirman que la arquitectura y β condicionan el resultado [14].

GANomaly. Frente a la optimización iterativa de AnoGAN, GANomaly aprende dos codificadores y un decodificador. Su generador produce $z = E_1(x)$, $\hat{x} = G(z)$ y $\hat{z} = E_2(\hat{x})$. Combina pérdida contextual, latente y adversarial; durante inferencia, $\|z - \hat{z}\|_1$ actúa como puntuación [8]. La comparación es relevante porque el entrenamiento adversarial puede mejorar representaciones, pero añade inestabilidad y coste.

Los benchmarks industriales como MVTec AD impulsaron protocolos comunes [15]. En medicina, BMAD extiende esa idea a seis conjuntos de cinco dominios y quince algoritmos [12]. Este trabajo no busca reproducir todo el leaderboard: aísla las tres familias solicitadas en la propuesta y controla las variables experimentales.

4. Datos y metodología

4.1. Chest-RSNA

BMAD reorganiza las 26.684 radiografías del desafío RSNA en el formato de detección de anomalías. Entrenamiento contiene 8.000 normales; validación, 70 normales y 1.420 anómalas; test, 781 normales y 16.413 anómalas. La copia local empleada contiene PNG legibles, monocromos y de 1024×1024 . El fuerte desequilibrio hace inadecuada la exactitud simple.

Las imágenes se convierten a un canal, se redimensionan bilinealmente a 64×64 y se escalan a $[0, 1]$. Esta resolución reduce el coste para CPU y permite una comparación controlada, pero puede borrar hallazgos pequeños; por ello se declara como limitación y una repetición a 128×128 constituye la ablación prioritaria, no una conclusión asumida.

4.2. Diseño experimental

Los modelos comparten dimensión latente 64, Adam con tasa $2 \cdot 10^{-4}$, lotes de 64 y 20 épocas. Para GANomaly se usan pesos 1, 50 y 1 en las pérdidas adversarial, contextual y latente. Para VAE se fija $\beta = 10^{-4}$, evitando que la regularización eclipse prematuramente la reconstrucción. Se ejecutan semillas 13, 42 y 73.

AE puntúa mediante MAE por imagen; VAE suma MAE y KL ponderada; GANomaly usa la distancia latente. Como las escalas no son comparables directamente, se comparan rankings (AUROC/AUPRC) y cada modelo obtiene su umbral exclusivamente en validación. Se maximiza exactitud balanceada y, ante empate, se favorece especificidad. El umbral se aplica sin cambios a test.

La métrica principal es AUROC. AUPRC refleja el rendimiento bajo prevalencia desigual, aunque debe interpretarse respecto a la alta proporción anómala del test. La exactitud balanceada evita que una clase numerosa domine; sensibilidad y especificidad muestran el compromiso clínicamente relevante. Se reportan media y desviación de las tres semillas, parámetros y tiempo.

La referencia supervisada reutiliza el mismo codificador y sustituye el decodificador por una salida binaria. De las 1.420 anomalías de validación se reservan, junto con igual número de normales de entrenamiento, 1.136 imágenes por clase para ajuste y 284 por clase para validación. La división es determinista para cada semilla y el test oficial permanece intacto. Se optimiza entropía cruzada binaria y se elige el checkpoint por AUROC de validación.

4.3. Reproducibilidad

El repositorio contiene rutas configurables, dependencias fijadas, semillas deterministas, guardado de checkpoints, puntuaciones CSV y configuración JSON. Las imágenes y los artefactos intermedios se excluyen de Git; se conserva un único checkpoint congelado para la demostración. El informe distingue mediante el campo `scientific_run` una ejecución completa de una prueba limitada, impidiendo que resultados de humo entren por error en la tabla final.

Como control no neuronal se calcularon nueve estadísticas predefinidas de intensidad y textura. Cada una se convirtió en distancia absoluta tipificada respecto al entrenamiento normal. La selección del control y su umbral usaron solo validación, igual que los modelos.

5. Resultados y análisis

5.1. Verificación y campaña final

La verificación local encuentra 8.000/1.490/17.194 imágenes en entrenamiento/validación/test, coincidiendo con BMAD. La campaña completa leyó las 26.684 radiografías y una ejecución de humo comprobó carga de datos, salida de los cuatro modelos, métricas y selección del umbral.

La campaña final ejecutó los tres modelos generativos y la referencia supervisada durante 20 épocas con semillas 13, 42 y 73, usando el test completo. La tabla presenta media y desviación estándar entre semillas.

Modelo	Parámetros	AUROC	AUPRC	Bal. acc.
AE	609.857	0,4566 $\pm$ 0,0163	0,9533	0,5105
VAE	740.993	0,4506 $\pm$ 0,0016	0,9526	0,5064
GANomaly	959.586	0,5636 $\pm$ 0,0150	0,9655	0,5484
Clasificador	175.025	0,8538$\pm$0,0070	0,9913	0,7717

La prevalencia anómala de test es 95,46 %; por eso AUPRC ronda 0,95 incluso en AE y VAE. Sus AUROC son inferiores a 0,5 en las seis ejecuciones: las anómalas presentan una mediana de error ligeramente menor que las normales. Reconstruir bien normalidad no produce aquí una puntuación discriminativa. GANomaly supera AE y VAE en cada semilla y es el único modelo con separación en la dirección esperada, pero su exactitud balanceada media queda en 0,55.

La referencia supervisada obtiene AUROC $0,8538 \pm 0,0070$ y exactitud balanceada $0,7717 \pm 0,0136$. Las tres ejecuciones alcanzan 0,8459, 0,8565 y 0,8590, por lo que la mejora no depende de una semilla aislada. La comparación no atribuye superioridad algorítmica directa: el clasificador recibe anomalías etiquetadas durante el ajuste y los detectores de una clase no.

5.2. Controles y análisis de errores

El control de gradiente medio, seleccionado en validación, obtiene AUROC 0,5981 y exactitud balanceada 0,5894. La diferencia centro–borde alcanza 0,5848 y el control multivariante diagonal 0,5754. Los tres igualan o superan el GANomaly medio. Por tanto, la hipótesis se acepta solo parcialmente: GANomaly mejora de forma consistente el AE, pero no demuestra una representación superior a señales estadísticas simples.

La inspección del GANomaly con mayor AUROC muestra entre los falsos positivos encuadres pediátricos, rotaciones, marcadores, proyecciones portátiles y cambios de contraste. Los falsos negativos conservan con frecuencia un encuadre adulto estandarizado pese a estar etiquetados como no normales. Esta evidencia visual, junto al control de gradiente, sugiere que parte de la señal procede del proceso de adquisición y no necesariamente de la patología. No se interpretan las imágenes clínicamente.




Figura 1: Falsos positivos y falsos negativos extremos de GANomaly, semilla 42. Las miniaturas se emplean únicamente para análisis metodológico.

6. Conclusiones

La propuesta se ha convertido en un estudio completo: dataset auditado, tres modelos generativos, una referencia supervisada, protocolos sin fuga, controles simples y análisis de errores. La contribución defendible no es afirmar que un autoencoder diagnostica patologías, sino medir bajo qué condiciones la hipótesis de reconstrucción separa normalidad y no normalidad.

GANomaly es el mejor modelo no supervisado: supera AE y VAE en las tres semillas y alcanza AUROC $0,5636 \pm 0,0150$. AE y VAE no son detectores útiles en esta configuración, pues quedan consistentemente por debajo de 0,5 aunque reconstruyen bien las normales. Sin embargo, el control de gradiente obtiene 0,5981 y evidencia que variaciones simples de textura o adquisición explican una parte importante de la separación. No se sostiene que GANomaly haya aprendido una señal clínica robusta ni que esté preparado para uso asistencial.

El resultado es útil y defendible: demuestra experimentalmente los límites de la hipótesis de reconstrucción,

cuantifica el beneficio y coste del entrenamiento adversarial, y detecta un atajo que quedaría oculto reportando solo AUPRC. La conclusión negativa respecto a utilidad clínica evita una afirmación injustificada.

La mejora mínima supervisada alcanza AUROC $0,8538 \pm 0,0070$ y exactitud balanceada $0,7717 \pm 0,0136$. Es el resultado práctico principal del trabajo: una arquitectura pequeña y explicable, sin ensamble ni búsqueda de algoritmos. Su límite debe quedar explícito: aprende las etiquetas disponibles y no resuelve la detección abierta de patologías desconocidas.

Para hacer tangible el resultado se entrega una demostración que recibe una radiografía, aplica el clasificador congelado de la semilla 42 y muestra probabilidad, umbral de validación y clase normal/anómala. Esta interfaz no cambia el experimento y recuerda explícitamente que la salida no es un diagnóstico.

Como trabajo futuro se priorizan una ablación a 128×128 , validación externa por pacientes y comparación con representaciones preentrenadas o autoencoders enmascarados [16, 11]. Solo después tendría sentido estudiar localización o despliegue.

Bibliografía

- [1] Guansong Pang, Chunhua Shen, Longbing Cao y Anton van den Hengel. «Deep Learning for Anomaly Detection: A Review». En: *ACM Computing Surveys* 54.2 (2021), págs. 1-38. DOI: [10.1145/3439950](https://doi.org/10.1145/3439950).
- [2] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich y Klaus-Robert Müller. «A Unifying Review of Deep and Shallow Anomaly Detection». En: *Proceedings of the IEEE* 109.5 (2021), págs. 756-795. DOI: [10.1109/JPROC.2021.3052449](https://doi.org/10.1109/JPROC.2021.3052449).
- [3] Geoffrey E. Hinton y Ruslan R. Salakhutdinov. «Reducing the Dimensionality of Data with Neural Networks». En: *Science* 313.5786 (2006), págs. 504-507. DOI: [10.1126/science.1127647](https://doi.org/10.1126/science.1127647).
- [4] Christoph Baur, Stefan Denner, Benedikt Wiestler, Shadi Albarqouni y Nassir Navab. «Autoencoders for Unsupervised Anomaly Segmentation in Brain MR Images: A Comparative Study». En: *Medical Image Analysis* 69 (2021), pág. 101952. DOI: [10.1016/j.media.2020.101952](https://doi.org/10.1016/j.media.2020.101952).
- [5] Diederik P. Kingma y Max Welling. «Auto-Encoding Variational Bayes». En: *International Conference on Learning Representations*. 2014. arXiv: [1312.6114](https://arxiv.org/abs/1312.6114).
- [6] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville y Yoshua Bengio. «Generative Adversarial Nets». En: *Advances in Neural Information Processing Systems*. Vol. 27. 2014, págs. 2672-2680.
- [7] Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Ursula Schmidt-Erfurth y Georg Langs. «Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery». En: *Information Processing in Medical Imaging*. 2017, págs. 146-157. DOI: [10.1007/978-3-319-59050-9_12](https://doi.org/10.1007/978-3-319-59050-9_12).
- [8] Samet Akçay, Amir Atapour-Abarghouei y Toby P. Breckon. «GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training». En: *Asian Conference on Computer Vision*. 2019, págs. 622-637. DOI: [10.1007/978-3-030-20893-6_39](https://doi.org/10.1007/978-3-030-20893-6_39).
- [9] Haibo Zhang, Wenping Guo, Shiqing Zhang, Hongsheng Lu y Xiaoming Zhao. «Unsupervised Deep Anomaly Detection for Medical Images Using an Improved Adversarial Autoencoder». En: *Journal of Digital Imaging* 35.2 (2022), págs. 153-161. DOI: [10.1007/s10278-021-00558-8](https://doi.org/10.1007/s10278-021-00558-8).
- [10] Xiaoyuan Guo, Judy Wawira Gichoya, Saptarshi Purkayastha e Imon Banerjee. *CVAD: A Generic Medical Anomaly Detector Based on Cascade VAE*. 2021. arXiv: [2110.15811](https://arxiv.org/abs/2110.15811).
- [11] Mariana-Iuliana Georgescu. «Masked Autoencoders for Unsupervised Anomaly Detection in Medical Images». En: *Procedia Computer Science: KES 2023*. 2023. arXiv: [2307.07534](https://arxiv.org/abs/2307.07534).
- [12] Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang y Xingyu Li. «BMAD: Benchmarks for Medical Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2024, págs. 4042-4053.
- [13] George Shih y col. «Augmenting the National Institutes of Health Chest Radiograph Dataset with Expert Annotations of Possible Pneumonia». En: *Radiology: Artificial Intelligence* 1.1 (2019), e180041. DOI: [10.1148/ryai.2019180041](https://doi.org/10.1148/ryai.2019180041).
- [14] Huy Hoang Nguyen, Cuong Nhat Nguyen, Xuan Tung Dao, Quoc Trung Duong, Dzung Pham Thi Kim y Minh-Tan Pham. *Variational Autoencoder for Anomaly Detection: A Comparative Study*. 2024. DOI: [10.48550/arXiv.2408.13561](https://doi.org/10.48550/arXiv.2408.13561). arXiv: [2408.13561](https://arxiv.org/abs/2408.13561).

- [15] Paul Bergmann, Michael Fauser, David Sattlegger y Carsten Steger. «MVTec AD: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, págs. 9592-9600. DOI: [10.1109/CVPR.2019.00982](https://doi.org/10.1109/CVPR.2019.00982).
- [16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár y Ross Girshick. «Masked Autoencoders Are Scalable Vision Learners». En: *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, págs. 16000-16009.